

Clasificación de Tumores Cerebrales en MRI mediante Redes Neuronales Convolucionales propias sobre el Dataset *Brain Tumor Classification MRI*

Abel Albuez Sánchez, Daniel Rios, Juan Torres y Javier Esquivel
Maestría en Analítica para Inteligencia de Negocios (MAIN)
Pontificia Universidad Javeriana, Bogotá D.C., Colombia
Profesor: Julio Omar Palacio Niño, M.Sc. Aprendizaje Profundo 2026

Resumen—Resumen del trabajo.

Index Terms—redes neuronales convolucionales, clasificación de imágenes, tumores cerebrales, MRI, aprendizaje profundo, F1-Score macro

I. INTRODUCCIÓN

II. OBJETIVOS

III. ANÁLISIS DEL PROBLEMA

IV. CONSTRUCCIÓN, ENTRENAMIENTO E IMPLEMENTACIÓN

IV-A. Modelo 1 — CNN Baseline

IV-B. Modelo 2 — CNN Profunda con BN y Dropout

El Modelo 2 se motiva en una observación del Modelo 1: la versión comparativa OkanNet, que añade *Batch Normalization* sobre el baseline manteniendo el resto de hiperparámetros, colapsa a un F1-macro de 0,4233 frente a los 0,6252 del baseline. La hipótesis es que el colapso no se debe a BN como técnica sino a su sensibilidad al régimen de entrenamiento ($\text{lr}=10^{-3}$, $\text{bs}=32$). El Modelo 2 contrasta esta hipótesis con una red sustancialmente más profunda —10 capas convolucionales VGG-style frente a 3 del baseline— entrenada con un régimen propio: AdamW, $\text{lr}=5 \times 10^{-4}$, $\text{bs}=64$, $\text{weight decay}=10^{-4}$, 50 épocas.

Se construyen dos variantes que comparten el mismo *backbone* convolucional pero difieren en el cabezal:

- **DeepCNN-BN.** Cabezal denso clásico con AdaptiveAvgPool2D(2,2) $\rightarrow$ Linear(2048,256) $\rightarrow$ BN1D $\rightarrow$ ReLU $\rightarrow$ Dropout(0,5) $\rightarrow$ Linear(256,4). Total: 5 240 292 parámetros.
- **DeepCNN-BN-GAP.** *Global Average Pooling* en lugar del FC denso: AdaptiveAvgPool2D(1,1) $\rightarrow$ Dropout(0,5) $\rightarrow$ Linear(512,4). Total: 4 716 260 parámetros (−524 K respecto a la variante FC).

El *backbone* se compone de cinco bloques con dos Conv2D 3×3 + BatchNorm2D + ReLU cada uno, con MaxPool2 $\times 2$ y Dropout2D de tasa creciente (0,10 $\rightarrow$ 0,30) entre bloques. La progresión de filtros es $32 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512$. El último bloque omite el MaxPool para producir salida 14×14 , requisito de divisibilidad del backend MPS bajo AdaptiveAvgPool2D.

Cuadro I
MÉTRICAS GLOBALES DEL MODELO 2 SOBRE *Testing*.

Modelo	Acc.	Prec.	Rec.	F1-Macro
Baseline (M1, ref.)	0,6751	0,7443	0,6508	0,6252
OkanNet (M1, ref.)	0,4467	0,4901	0,4634	0,4233
DeepCNN-BN	0,6472	0,7403	0,6351	0,5961
DeepCNN-BN-GAP	0,5558	0,6765	0,5482	0,5176

La hipótesis a contrastar entre las dos variantes es si el cabezal denso aporta capacidad discriminativa real frente al GAP cuando el *backbone* ya tiene profundidad suficiente.

IV-C. Modelo 3 — CNN con Técnica Avanzada

V. RESULTADOS

V-A. Modelo 2: Resultados sobre Testing

La Tabla I reporta las métricas globales sobre el conjunto *Testing* (holdout oficial de 394 imágenes).

Tres observaciones se desprenden:

(1) *BN funciona con régimen propio*: DeepCNN-BN supera a OkanNet en 17,28 puntos porcentuales de F1-macro (0,5961 vs 0,4233), pese a tener $\sim 3,3 \times$ más capas convolucionales con BN. Las curvas de validación de ambas variantes del Modelo 2 son monótonas crecientes y alcanzan F1-val de 0,9112 y 0,8988 respectivamente, sin disparar *early stopping*. Esto invalida la interpretación “BN es perjudicial” del Modelo 1 y la reformula como “BN es sensible al régimen de hiperparámetros”.

(2) *FC supera a GAP*: La variante con cabezal denso mejora a la variante GAP en 7,85 puntos de F1-macro, pese a compartir el *backbone*. La brecha se concentra en *meningioma_tumor* (+14,6 pp), clase con mayor variabilidad intra-clase. Los 524 K parámetros adicionales del cabezal FC sí aportan capacidad discriminativa real en este corpus.

(3) *Distribution shift domina*: Ambas variantes sufren una caída de ~ 30 puntos entre validación y prueba, idéntica a la del baseline. DeepCNN-BN *no* supera al baseline en *Testing* (−2,91 pp). Esto indica que la limitación dominante no es la capacidad del modelo sino la divergencia distribucional entre *Training* y *Testing* en el dataset oficial. La clase *glioma_tumor* resulta particularmente afectada: Precisión de 1,0000 (sin

falsos positivos) pero Recall de 0,1600, patrón que reproduce el sesgo *glioma* $\rightarrow$ *meningioma* del baseline. El aumento de capacidad arquitectónica no resuelve este sesgo.

V-B. Modelo 3: Resultados

VI. CONCLUSIONES