

Clasificación de Tumores Cerebrales en MRI mediante Redes Neuronales Convolucionales propias sobre el Dataset *Brain Tumor Classification MRI*

Abel Albuez Sánchez, Daniel Rios, Juan Torres y Javier Esquivel

Maestría en Analítica para Inteligencia de Negocios (MAIN)

Pontificia Universidad Javeriana, Bogotá D.C., Colombia

Profesor: Julio Omar Palacio Niño, M.Sc. Aprendizaje Profundo 2026

Resumen—La clasificación automática de tumores cerebrales en imágenes de resonancia magnética (MRI) es una tarea relevante de apoyo al diagnóstico radiológico. Este trabajo aborda la clasificación de cuatro categorías —*glioma*, *meningioma*, *pituitary* y *no_tumor*— sobre el dataset público *Brain Tumor Classification MRI* de Kaggle (3 264 imágenes), comparando tres arquitecturas convolucionales *propias* entrenadas desde cero, sin *transfer learning*. Las redes evaluadas son una CNN *baseline* de 3 capas convolucionales, una CNN profunda de 10 capas con *Batch Normalization* y *Dropout2d*, y MRIResNet, una arquitectura residual con atención *Squeeze-and-Excitation* y preprocesamiento multimodal CLAHE+Sobel de 5 canales. MRIResNet alcanza el mejor F1-macro sobre el *holdout* oficial (0,6593), +3,41 pp sobre el *baseline*, mientras que la CNN profunda confirma que *Batch Normalization* requiere un régimen de hiperparámetros propio para no colapsar. Una caída sistemática de ~ 30 puntos entre validación y prueba indica un *distribution shift* entre las particiones oficiales que ningún aumento de capacidad resuelve por completo.

Index Terms—redes neuronales convolucionales, clasificación de imágenes, tumores cerebrales, MRI, aprendizaje profundo, F1-Score macro

I. INTRODUCCIÓN

El diagnóstico temprano de tumores cerebrales constituye uno de los retos más relevantes de la neuro-oncología contemporánea. La resonancia magnética (MRI, *Magnetic Resonance Imaging*) es la modalidad de imagen de referencia para la detección y caracterización de estas lesiones; sin embargo, su interpretación depende fuertemente de la experiencia del radiólogo y está sujeta a variabilidad inter-observador. En este contexto, los sistemas de apoyo basados en aprendizaje profundo han mostrado resultados prometedores como herramientas de cribado y segunda opinión, capaces de procesar grandes volúmenes de estudios de forma consistente.

Este trabajo propone, entrena y evalúa tres arquitecturas convolucionales *propias* sobre el dataset público *Brain Tumor Classification MRI* [1]. A diferencia de la literatura mayoritaria sobre el corpus, que emplea *fine-tuning* de redes pre-entrenadas (VGG16 [2], ResNet50 [3], MobileNetV2), las tres redes se entrenan desde cero. El énfasis metodológico se sitúa, por tanto, en la comprensión del impacto de cada bloque arquitectónico —*Batch Normalization*, *Dropout2d*, conexiones residuales, atención de canales, preprocesamiento

estructural— sobre el rendimiento y la generalización a una partición de prueba afectada por *distribution shift*.

Contribuciones. (i) Replicación crítica de OkanNet, mostrando que la incorporación de *Batch Normalization* bajo el régimen de hiperparámetros del *baseline* ($lr = 10^{-3}$, batch = 32) degrada el F1-macro en 20,19 pp, y demostrando que una CNN profunda con BN entrenada bajo un régimen propio ($lr = 5 \times 10^{-4}$, batch = 64, AdamW) recupera ese rendimiento. (ii) Diseño de MRIResNet, una arquitectura residual con atención SE que incorpora un preprocesamiento multimodal explícito (CLAHE + Sobel) y supera al *baseline* usando $\sim 4 \times$ menos parámetros. (iii) Análisis del *distribution shift* entre las particiones oficiales *Training/Testing* del dataset, identificándolo como la limitación dominante de generalización por encima de la capacidad arquitectónica.

II. OBJETIVOS

Objetivo general. Diseñar, entrenar y evaluar tres arquitecturas propias de redes neuronales convolucionales para la clasificación automática de imágenes MRI cerebrales en cuatro categorías (*glioma*, *meningioma*, *no_tumor* y *pituitary*), sin emplear pesos preentrenados.

Objetivos específicos. (i) Construir un *baseline* convolucional ligero (Modelo 1) que sirva como referencia y replicar OkanNet [4] como contraste académico del impacto de BN bajo un régimen de hiperparámetros idéntico. (ii) Diseñar una CNN profunda (Modelo 2) con BN y *Dropout2d* en cada bloque, junto a una variante con *Global Average Pooling* (GAP), para aislar el aporte del cabezal denso. (iii) Construir un Modelo 3 más avanzado (MRIResNet) con bloques residuales, atención SE y preprocesamiento multimodal CLAHE+Sobel desde cero. (iv) Reportar y comparar las cuatro métricas estándar (*Accuracy*, *Precision*, *Recall*, *F1-Score macro-averaged*) y las matrices de confusión sobre el *holdout* oficial.

III. ANÁLISIS DEL PROBLEMA

III-A. Dataset

El dataset *Brain Tumor Classification MRI* contiene 3 264 imágenes de resonancia cerebral en cuatro clases. La partición

Cuadro I
DISTRIBUCIÓN DE IMÁGENES POR CLASE Y PARTICIÓN.

Clase	Train	Test	Total
glioma_tumor	826	100	926
meningioma_tumor	822	115	937
no_tumor	395	105	500
pituitary_tumor	827	74	901
Total	2 870	394	3 264

oficial entrega 2 870 imágenes para entrenamiento y 394 para prueba (Tabla I).

III-B. Desafíos identificados

Desbalance de clases. *no_tumor* es la clase minoritaria ($\sim 1:2$ respecto a las clases tumorales). Para mitigarlo se incorpora *class_weight* balanceado en la función de pérdida CrossEntropyLoss.

Heterogeneidad dimensional. Las imágenes presentan resoluciones entre 59×80 px y 1024×768 px. Se redimensiona todo a 224×224 px, un compromiso entre detalle anatómico y costo computacional consistente con las arquitecturas CNN modernas.

Variabilidad fotométrica. Los *gliomas* son hipointensos (media 36,23, mediana 14), los *pituitarios* más concentrados (mediana 50) y *no_tumor* presenta la mayor desviación estándar (59,63), reflejando la diversidad anatómica del cerebro sano. Estas diferencias constituyen señales explotables por la CNN a nivel de filtros convolucionales.

Distribution shift. Como se documenta en Resultados, los tres modelos sufren una caída sistemática de ~ 30 puntos entre F1-macro de validación y de prueba, atribuible a la divergencia distribucional entre las particiones oficiales del corpus.

III-C. Métricas y protocolo

Se reportan *Accuracy*, *Precision*, *Recall* y F1-Score, todas en su variante *macro-averaged* dado el desbalance del corpus, junto a la matriz de confusión normalizada por clase real. El F1-macro es la métrica principal de comparación. Sobre *Training* se aplica una división interna 80/20 para validación; el conjunto *Testing* se reserva como *holdout* independiente y se usa únicamente para la evaluación final reportada en la Sección V.

IV. CONSTRUCCIÓN, ENTRENAMIENTO E IMPLEMENTACIÓN

IV-A. Modelo 1 — CNN Baseline y OkanNet

El Modelo 1 implementa una CNN *baseline* ligera inspirada en OkanNet [4] y en la red de Gupta *et al.* [5]: tres bloques secuenciales Conv2D(3×3)-ReLU-MaxPool2D(2×2) con filtros $16 \rightarrow 32 \rightarrow 64$, seguidos de un cabezal denso Linear($50\,176 \rightarrow 128$)-ReLU-Dropout(0,5)-Linear($128 \rightarrow 4$). La inicialización es *Kaiming Normal* (*fan_out* para Conv2D, *fan_in* para Linear). Total: 6 446 756 parámetros, dominados al 99,6 % por la primera capa totalmente conectada.

Como contraste académico se replica **OkanNet**, idéntica al *baseline* pero con BatchNorm2D tras cada Conv2D (+224 parámetros). Los hiperparámetros de entrenamiento se mantienen idénticos entre ambas redes para aislar el efecto de BN.

Hiperparámetros (M1). Adam ($\beta_1=0,9$, $\beta_2=0,999$), $lr_0=10^{-3}$, ReduceLROnPlateau(factor 0,5, paciencia 3), CrossEntropyLoss con *class_weight*, *batch* = 32, 40 épocas máx., *early stopping* con paciencia 7 sobre F1-macro de validación, *seed* 42.

IV-B. Modelo 2 — CNN Profunda con BN y Dropout

El Modelo 2 se motiva en el colapso de OkanNet bajo el régimen del Modelo 1: la hipótesis es que el fallo no se debe a BN como técnica sino a su sensibilidad al *learning rate* y al tamaño de *batch*. El Modelo 2 contrasta esta hipótesis con una red sustancialmente más profunda —10 capas convolucionales VGG-style frente a 3 del *baseline*— entrenada con un régimen propio: AdamW, $lr=5 \times 10^{-4}$, *batch*=64, *weight decay*= 10^{-4} , 50 épocas máx.

Se construyen dos variantes que comparten el mismo *backbone* convolucional pero difieren en el cabezal:

- **DeepCNN-BN.** Cabezal denso clásico con AdaptiveAvgPool2D(2,2) $\rightarrow$ Linear($2048 \rightarrow 256$) $\rightarrow$ BN1D $\rightarrow$ ReLU $\rightarrow$ Dropout(0,5) $\rightarrow$ Linear($256 \rightarrow 4$). Total: 5 240 292 parámetros.
- **DeepCNN-BN-GAP.** *Global Average Pooling* en lugar del FC denso: AdaptiveAvgPool2D(1,1) $\rightarrow$ Dropout(0,5) $\rightarrow$ Linear($512 \rightarrow 4$). Total: 4 716 260 parámetros (−524 K respecto a la variante FC).

El *backbone* se compone de cinco bloques con dos Conv2D(3×3) + BatchNorm2D + ReLU cada uno, MaxPool(2×2) y Dropout2D de tasa creciente (0,10 $\rightarrow$ 0,30) entre bloques. La progresión de filtros es $32 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512$. El último bloque omite el MaxPool para producir salida 14×14 , requisito de divisibilidad del backend MPS bajo AdaptiveAvgPool2D.

IV-C. Modelo 3 — MRIResNet con Atención SE

El Modelo 3 (MRIResNet) extiende el *baseline* en tres ejes complementarios.

(a) **Preprocesamiento multimodal de 5 canales.** En lugar de RGB ($B, 3, 224, 224$), el modelo recibe un tensor ($B, 5, 224, 224$) generado mediante CLAHE [8] (*clipLimit* = 2,0, *tileGrid* = 8×8) sobre la imagen en escala de grises — que mejora el contraste local sin amplificar ruido global— seguido de filtro Sobel $G = \sqrt{G_x^2 + G_y^2}$ sobre la imagen CLAHE para extraer gradientes espaciales. Los canales finales son [*R*, *G*, *B*, CLAHE, Sobel], normalizados canal a canal con estadísticos de *Training*. Este diseño está conceptualmente inspirado en los hallazgos de Hubel y Wiesel [7] sobre selectividad orientacional en la corteza visual primaria.

(b) **Bloques residuales.** Cada bloque aprende $\mathcal{F}(\mathbf{x}) + \mathbf{x}$ [3] con estructura interna Conv(3×3)-BN-ReLU-Conv(3×3)-

Cuadro II
MÉTRICAS GLOBALES SOBRE *Testing*.

Modelo	Acc.	Prec.	Rec.	F1-Macro
Baseline (M1)	0,6751	0,7443	0,6508	0,6252
OkanNet (comp.)	0,4467	0,4901	0,4634	0,4233
DeepCNN-BN (M2)	0,6472	0,7403	0,6351	0,5961
DeepCNN-BN-GAP (M2)	0,5558	0,6765	0,5482	0,5176
MRIResNet (M3)	0,7107	0,7947	0,6992	0,6593

Cuadro III
F1-SCORE POR CLASE SOBRE *Testing*.

Clase	Base.	Okan.	DeepCNN	GAP	MRIResNet
glioma	0,3307	0,2597	0,2759	0,2735	0,2906
mening.	0,7766	0,2517	0,7137	0,5676	0,7912
no_tumor	0,7445	0,5337	0,7331	0,6355	0,7816
pituitary	0,6491	0,6479	0,6618	0,5938	0,7737

$\text{BN} \oplus \text{x-ReLU}$. Cuando los canales de entrada y salida difieren, el camino *skip* incorpora una proyección $\text{Conv}(1 \times 1) + \text{BN}$.

(c) **Atención Squeeze-and-Excitation (SE)** [6]. El módulo SE recalibra los canales en tres etapas: *squeeze* mediante GAP global, *excitation* mediante $\text{FC-ReLU-FC-Sigmoid}$ con ratio de reducción $r=8$, y reescalado multiplicativo $\hat{x}_c = s_c \cdot x_c$.

La arquitectura final consta de 1 676 284 parámetros entrenables (apenas el 26 % del *baseline*), gracias al uso de *Global Average Pooling* en el cabezal. Se entrena con AdamW ($\text{lr} = 10^{-4}$, $\text{weight decay} = 10^{-4}$), batch = 32, 50 épocas máx., *early stopping* con paciencia 10 sobre F1-macro de validación.

IV-D. Implementación

Toda la implementación se realiza en Python con PyTorch sobre Apple Silicon (backend MPS). El código se organiza en `models/model{1,2,3}/` como tres paquetes auto-contenidos, con utilidades compartidas en `models/common/`. Cada modelo expone una CLI (`train.py --arch <name>`) y reportes incrementales por época en CSV.

V. RESULTADOS

V-A. Métricas globales sobre *Testing*

La Tabla II reporta las métricas sobre el *holdout* oficial de 394 imágenes.

V-B. Modelo 1 (*Baseline* + *OkanNet*)

El *baseline* alcanza F1-macro de 0,6252. La incorporación de BN sin ajuste de hiperparámetros (*OkanNet*) lo desploma a 0,4233 (−20,19 pp), con convergencia inestable y disparo de *early stopping* en la época 17. Este resultado no invalida BN como técnica, sino que evidencia su sensibilidad al régimen $\text{lr} = 10^{-3}/\text{batch} = 32$. El sesgo *glioma*→*meningioma* domina los errores: el 79 % de los gliomas reales se asigna mayoritariamente como meningioma, generando Precision alta (0,7778) pero Recall bajísimo (0,2100) sobre la clase *glioma*.




Figura 1. Matriz de confusión normalizada de DeepCNN-BN sobre *Testing*.




Figura 2. F1-macro de validación de DeepCNN-BN y DeepCNN-BN-GAP a lo largo del entrenamiento. Ambas convergen sin disparar *early stopping*, contrastando con la inestabilidad de *OkanNet*.

V-C. Modelo 2 (*DeepCNN-BN* y *DeepCNN-BN-GAP*)

DeepCNN-BN alcanza 0,5961 de F1-macro (+17,28 pp sobre *OkanNet*, −2,91 pp sobre el *baseline*). Las curvas de validación son monótonas crecientes hasta 0,9112 en la época 50, sin disparar *early stopping*, lo que confirma que BN funciona bajo el régimen adaptado (AdamW $\text{lr} = 5 \times 10^{-4}$, batch = 64, $\text{weight decay} = 10^{-4}$).

La variante GAP rinde 7,85 pp por debajo del FC denso (0,5176 vs 0,5961), pese a compartir el *backbone*: los ~ 524K parámetros adicionales del cabezal FC sí aportan capacidad discriminativa real en este corpus, particularmente en *meningioma* (+14,6 pp) y *no_tumor* (+9,8 pp). La hipótesis “GAP rinde equivalentemente cuando el *backbone* es suficientemente profundo” no se sostiene aquí.

V-D. Modelo 3 (*MRIResNet*)

MRIResNet alcanza el mejor F1-macro del trabajo (**0,6593**), +3,41 pp sobre el *baseline* y +6,32 pp sobre DeepCNN-BN, usando ~ 4× menos parámetros que el *baseline*. La mejora se concentra en las tres clases




Figura 3. Matriz de confusión normalizada de MRIResNet sobre *Testing*.

“aprendibles”: *meningioma* +1,46 pp, *no_tumor* +3,71 pp y, especialmente, *pituitary* +12,46 pp respecto al *baseline*. La clase *glioma_tumor* sigue siendo el cuello de botella en los tres modelos (F1 entre 0,26 y 0,33), consistente con una hipótesis de divergencia distribucional: los gliomas del *Testing* parecen provenir de subtipos o protocolos sub-representados en *Training*, lo cual no se compensa con mayor capacidad arquitectónica.

V-E. Distribution shift

Los cinco modelos exhiben una caída sistemática de ~ 30 pp entre F1-macro de validación y de prueba (*baseline*: $0,92 \rightarrow 0,63$; DeepCNN-BN: $0,91 \rightarrow 0,60$; MRIResNet: $\sim 0,90 \rightarrow 0,66$). Pese a triplicar la profundidad, añadir BN, regularización con *weight decay* y preprocesamiento multimodal, el F1-macro de prueba mejora solo 3,41 pp respecto al *baseline*. Esto indica que el factor dominante de generalización en este corpus **no es la capacidad del modelo sino el *distribution shift*** entre las particiones oficiales.

VI. CONCLUSIONES

Las CNN propias entrenadas desde cero alcanzan un F1-macro de hasta 0,6593 sobre el *holdout* oficial, valor que sitúa al sistema como herramienta de *cribado* complementaria al criterio radiológico, pero *no* como clasificador clínico autónomo. La clase *glioma_tumor* es el cuello de botella sistemático en los tres modelos, con F1 entre 0,26 y 0,33 y Recall por debajo del 25 % incluso en MRIResNet.

Del análisis comparativo se desprenden tres lecciones metodológicas: (i) *Batch Normalization* no es intrínsecamente perjudicial; su efectividad depende críticamente del régimen de entrenamiento, como demuestra el contraste OkanNet vs DeepCNN-BN. (ii) Las técnicas avanzadas (residuales,

atención SE, preprocesamiento estructural CLAHE + Sobel) aportan ganancias reales pero modestas en *Testing* (+3,41 pp en F1-macro), porque la limitación dominante es distribucional, no arquitectónica. (iii) El cabezal denso aporta capacidad discriminativa relevante frente al GAP en este corpus, contrariamente a la intuición “GAP es suficiente si el *backbone* es profundo”.

Limitaciones y trabajo futuro. La principal limitación es la pérdida sistemática de ~ 30 puntos entre validación y prueba, atribuible al *split* oficial del dataset y no a las arquitecturas evaluadas. Las direcciones más prometedoras son (i) *transfer learning* desde redes pre-entrenadas, capaces de capturar invariancias robustas frente al *shift*, abordado en la fase de investigación complementaria de este proyecto; (ii) *domain adaptation* entre particiones; y (iii) validación cruzada estratificada sobre el conjunto unificado para cuantificar la verdadera capacidad de generalización de cada modelo independientemente del *split* oficial.

REFERENCIAS

- [1] S. Bhuvaji, “Brain Tumor Classification (MRI),” Kaggle, 2020.
- [2] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” *arXiv:1409.1556*, 2014.
- [3] K. He, X. Zhang, S. Ren and J. Sun, “Deep residual learning for image recognition,” in *CVPR*, 2016.
- [4] A. Uçar and Y. Kurt, “OkanNet: a lightweight CNN for MRI tumor classification,” 2026.
- [5] R. Gupta *et al.*, “Classification of brain tumor images using CNN,” 2023.
- [6] J. Hu, L. Shen and G. Sun, “Squeeze-and-excitation networks,” in *CVPR*, 2018.
- [7] D. H. Hubel and T. N. Wiesel, “Receptive fields of single neurones in the cat’s striate cortex,” *J. Physiol.*, vol. 148, 1959.
- [8] K. Zuiderveld, “Contrast limited adaptive histogram equalization,” in *Graphics Gems IV*, 1994.