

# Clasificación de Tumores Cerebrales en MRI mediante Redes Neuronales Convolucionales propias sobre el Dataset *Brain Tumor Classification MRI*

Abel Albuez Sánchez, Daniel Rios, Juan Torres y Javier Esquivel  
Maestría en Analítica para Inteligencia de Negocios (MAIN)  
Pontificia Universidad Javeriana, Bogotá D.C., Colombia  
Profesor: Julio Omar Palacio Niño, M.Sc. Aprendizaje Profundo 2026

**Resumen**—La clasificación automática de tumores cerebrales en imágenes de resonancia magnética (MRI) constituye una tarea relevante para el apoyo al diagnóstico radiológico. Este trabajo aborda la clasificación de cuatro categorías —*glioma*, *meningioma*, *pituitary* y *no tumor*— sobre el dataset público *Brain Tumor Classification MRI* de Kaggle (3 264 imágenes), mediante tres arquitecturas propias de redes neuronales convolucionales (CNN) entrenadas desde cero, sin emplear *transfer learning*. Se reporta un análisis exploratorio detallado del dataset —incluyendo distribución por clases, dimensionalidad y estadísticos de intensidad—, un pipeline de preprocesamiento con normalización tipo ImageNet y *data augmentation*, y un protocolo de evaluación basado en *F1-Score* macro, adecuado para escenarios con desbalance de clases.

**Index Terms**—clasificación de tumores cerebrales, redes neuronales convolucionales, resonancia magnética, aprendizaje profundo, PyTorch, *F1-Score* macro

## I. OBJETIVO DEL PROYECTO

### I-A. Contexto Clínico

El diagnóstico temprano y preciso de tumores cerebrales constituye uno de los retos más relevantes de la neuro-oncología contemporánea. La resonancia magnética (MRI, *Magnetic Resonance Imaging*) es la modalidad de imagen de referencia para la detección y caracterización de estas lesiones; sin embargo, su interpretación depende fuertemente de la experiencia del radiólogo y está sujeta a variabilidad inter-observador. En este contexto, los sistemas de apoyo al diagnóstico basados en aprendizaje profundo han mostrado resultados prometedores como herramientas de cribado y segunda opinión, capaces de procesar grandes volúmenes de estudios de manera consistente.

### I-B. Objetivo Técnico

El presente proyecto tiene como objetivo diseñar, entrenar y evaluar tres arquitecturas propias de redes neuronales convolucionales (CNN) para la clasificación automática de imágenes MRI cerebrales en cuatro categorías: *glioma\_tumor*, *meningioma\_tumor*, *no\_tumor* y *pituitary\_tumor*. Se utiliza el dataset público *Brain Tumor Classification MRI* disponible en Kaggle. De manera explícita, este trabajo **no** emplea técnicas de *transfer learning* ni pesos preentrenados sobre ImageNet u otros corpus; el énfasis pedagógico está en la construcción de arquitecturas convolucionales desde cero y en la comprensión del impacto de sus hiperparámetros y bloques constitutivos.

Cuadro I: Distribución de imágenes por clase y partición.

| Clase            | Train        | Test       | Total        |
|------------------|--------------|------------|--------------|
| glioma_tumor     | 826          | 100        | 926          |
| meningioma_tumor | 822          | 115        | 937          |
| no_tumor         | 395          | 105        | 500          |
| pituitary_tumor  | 827          | 74         | 901          |
| <b>Total</b>     | <b>2 870</b> | <b>394</b> | <b>3 264</b> |

### I-C. Criterios de Evaluación

La evaluación de los modelos se realizará mediante un conjunto de métricas clásicas de clasificación multiclase: *Accuracy*, *Precision*, *Recall* y *F1-Score* en su variante *macro-averaged*, complementadas con la matriz de confusión por modelo. Dado el desbalance entre clases observado durante el análisis exploratorio (Sección II), el *F1-macro* se adopta como métrica principal de comparación, por su robustez frente a clases minoritarias.

## II. ANÁLISIS DEL DATASET Y DIMENSIONALIDAD

### II-A. Descripción del Dataset

El conjunto de datos *Brain Tumor Classification MRI*, publicado en Kaggle, contiene **3 264 imágenes** de resonancia magnética cerebral organizadas en cuatro clases diagnósticas: *glioma\_tumor*, *meningioma\_tumor*, *pituitary\_tumor* y *no\_tumor* (estudios sin hallazgos tumorales). Los autores del dataset proporcionan una partición oficial entre conjuntos de entrenamiento y prueba que se respeta en este trabajo. La Tabla I resume su distribución.

El conjunto de entrenamiento concentra el **87,9 %** de las imágenes (2 870), mientras que el conjunto de prueba representa el **12,1 %** restante (394 imágenes). El conjunto *Testing* se reserva como *holdout* independiente para la evaluación final de los modelos, y la subdivisión interna para validación se realiza únicamente sobre *Training* (véase Sección IV-B).

### II-B. Balance de Clases

El análisis de balance evidencia que la clase *no\_tumor* es la minoritaria en entrenamiento, con aproximadamente **395** imágenes, frente a **~825** para cada una de las tres clases tumorales. Esta proporción asimétrica ( $\sim 1:2$ ) puede inducir




Figura 1: Distribución absoluta por clase y partición.




Figura 2: Proporción relativa en entrenamiento.

sesgos durante el aprendizaje, llevando al modelo a sub-representar la clase minoritaria y a inflar artificialmente la *Accuracy* global.

Como estrategia de compensación se adopta el uso de pesos por clase (*class\_weight*) en la función de pérdida *Cross-Entropy*, con ponderaciones inversamente proporcionales a la frecuencia relativa de cada clase en el conjunto de entrenamiento. Esto incrementa la magnitud del gradiente para errores cometidos sobre la clase minoritaria sin alterar la distribución de muestras observadas. Las Figuras 1 y 2 ilustran gráficamente esta distribución.

## II-C. Análisis de Dimensionalidad

Se inspeccionó una muestra de **80 imágenes por clase** para caracterizar la variabilidad en resolución espacial del dataset. Las imágenes presentan resoluciones altamente heterogéneas: las dimensiones máximas observadas alcanzan **1024×768 px** y las mínimas **59×80 px**. La relación de aspecto también varía considerablemente entre estudios, reflejo de las diferencias entre equipos de adquisición y protocolos clínicos.

Dada esta heterogeneidad, se establece el redimensionamiento uniforme a **224×224 px** como paso obligatorio del pipeline. Esta resolución constituye un compromiso adecuado entre el nivel de detalle anatómico preservado y el costo computacional, y es además el formato canónico de las arquitecturas CNN modernas, lo que facilita comparaciones posteriores. Las Figuras 3 y 4 muestran respectivamente el histograma de resoluciones y la distribución de relaciones de aspecto observadas por clase.

## II-D. Análisis Estadístico de Intensidades

Se analizaron las distribuciones de intensidad de píxeles (escala de grises) y canales RGB por clase, con el fin de identificar diferencias fotométricas potencialmente discriminativas para el modelado. La Tabla II resume los estadísticos descriptivos.




Figura 3: Histograma de resoluciones (ancho × alto) en el dataset.




Figura 4: Distribución de relaciones de aspecto por clase.

Cuadro II: Estadísticas de intensidad (escala 0–255) por clase.

| Clase            | Media | Std   | Mín | Máx | Mediana |
|------------------|-------|-------|-----|-----|---------|
| glioma_tumor     | 36,23 | 41,43 | 0   | 255 | 14      |
| meningioma_tumor | 44,56 | 47,77 | 0   | 255 | 28      |
| no_tumor         | 52,21 | 59,63 | 0   | 255 | 22      |
| pituitary_tumor  | 49,50 | 42,94 | 0   | 255 | 50      |

Los *gliomas* presentan los valores más bajos de media (36,23) y mediana (14), lo que los caracteriza como tejidos relativamente **hipointensos** en la modalidad analizada. Los tumores *pituitarios*, en contraste, presentan la mediana más alta (50) y la menor dispersión relativa, indicando intensidades más concentradas y homogéneas. La clase *no\_tumor* muestra la mayor desviación estándar (59,63), consistente con la variedad anatómica del cerebro sano sin focalización lesional. Estas diferencias fotométricas constituyen señales útiles que una CNN puede explotar a nivel de filtros convolucionales de bajo nivel.

Para estabilizar el entrenamiento se aplicará normalización *Z-score* sobre los tres canales utilizando los estadísticos canónicos de ImageNet ( $\mu = [0,485, 0,456, 0,406]$ ,  $\sigma = [0,229, 0,224, 0,225]$ ), valores ampliamente adoptados en la literatura como referencia robusta incluso cuando no se emplea *transfer learning*. Las Figuras 5 y 6 complementan visualmente este análisis.

## II-E. Imagen Promedio y Muestras por Clase

La Figura 7 presenta la imagen promedio por clase, calculada como la media píxel a píxel de 100 imágenes redimensionadas a 224×224 px. Los gliomas exhiben regiones **hipointensas difusas**, de bordes poco definidos, consistente con su naturaleza infiltrativa. Los tumores *pituitarios* tienden a concentrarse en la zona central, reflejando la ubicación anatómica de la glándula hipófisis. Los meningiomas muestran




Figura 5: Diagramas de caja de intensidades de píxel por clase.




Figura 6: Distribución de intensidades por canal RGB y por clase.




Figura 7: Imagen promedio por clase (100 imgs, 224×224 px).

patrones intermedios con tendencia a localizarse en la periferia. La clase *no\_tumor*, al promediar tejidos cerebrales sanos en distintas orientaciones, produce una imagen más difusa y centralmente simétrica.

La Figura 8 ilustra cinco ejemplos representativos por clase. Se evidencia alta variabilidad intra-clase en orientación, escala y contraste, lo que justifica el uso de *data augmentation* — rotación  $\pm 15^\circ$ , *flip* horizontal y variación de brillo— durante el entrenamiento para mejorar la capacidad de generalización




Figura 8: 5 muestras por clase — *Training*.

Cuadro III: Pipeline de preprocesamiento propuesto.

| # | Paso                      | Justificación                                                           |
|---|---------------------------|-------------------------------------------------------------------------|
| 1 | Resize 224×224 px         | Resoluciones heterogéneas requieren entrada uniforme.                   |
| 2 | Conversión a RGB          | Algunas imágenes en escala de grises; se unifica formato.               |
| 3 | Z-score ( $\mu$ ImageNet) | Estabiliza el gradiente y mejora la convergencia.                       |
| 4 | <i>Data augmentation</i>  | Rotación $\pm 15^\circ$ , <i>flip</i> horizontal y variación de brillo. |
| 5 | <i>class_weight</i>       | Compensa el desbalance de <i>no_tumor</i> .                             |
| 6 | Split 80/20 Training      | Separa validación sin contaminar el <i>holdout</i> oficial.             |

del modelo.

## II-F. Plan de Preprocesamiento

A partir de los hallazgos anteriores, se define el pipeline de preprocesamiento resumido en la Tabla III, aplicado de forma consistente a las tres arquitecturas evaluadas.

## III. METODOLOGÍA

### III-A. Métricas de Evaluación

Para evaluar las arquitecturas propuestas se emplea un conjunto de métricas estándar de clasificación multiclase:

- **Accuracy:** proporción global de aciertos,  $\text{Acc} = (TP + TN) / (TP + TN + FP + FN)$ .
- **Precision (macro):** promedio no ponderado de la precisión por clase,  $\frac{1}{C} \sum_c TP_c / (TP_c + FP_c)$ .
- **Recall (macro):** promedio no ponderado de la sensibilidad por clase,  $\frac{1}{C} \sum_c TP_c / (TP_c + FN_c)$ .
- **F1-Score (macro):** media armónica de Precision y Recall,  $F1 = 2 \cdot P \cdot R / (P + R)$ , calculada por clase y promediada de forma no ponderada.
- **Matriz de confusión:** análisis cualitativo de los errores entre pares de clases.

Cuadro IV: Arquitectura del Modelo 1 (CNN Baseline). Entrada ( $B, 3, 224, 224$ ).

| #                             | Capa         | Filt. | Kernel       | Stride | Salida ( $C, H, W$ ) | Params    |
|-------------------------------|--------------|-------|--------------|--------|----------------------|-----------|
| 1                             | Conv2D       | 16    | $3 \times 3$ | 1      | (16, 224, 224)       | 448       |
| 2                             | ReLU         | —     | —            | —      | (16, 224, 224)       | 0         |
| 3                             | MaxPool2D    | —     | $2 \times 2$ | 2      | (16, 112, 112)       | 0         |
| 4                             | Conv2D       | 32    | $3 \times 3$ | 1      | (32, 112, 112)       | 4 640     |
| 5                             | ReLU         | —     | —            | —      | (32, 112, 112)       | 0         |
| 6                             | MaxPool2D    | —     | $2 \times 2$ | 2      | (32, 56, 56)         | 0         |
| 7                             | Conv2D       | 64    | $3 \times 3$ | 1      | (64, 56, 56)         | 18 496    |
| 8                             | ReLU         | —     | —            | —      | (64, 56, 56)         | 0         |
| 9                             | MaxPool2D    | —     | $2 \times 2$ | 2      | (64, 28, 28)         | 0         |
| 10                            | Flatten      | —     | —            | —      | (50 176, )           | 0         |
| 11                            | Linear       | —     | —            | —      | (128, )              | 6 422 656 |
| 12                            | ReLU         | —     | —            | —      | (128, )              | 0         |
| 13                            | Dropout(0.5) | —     | —            | —      | (128, )              | 0         |
| 14                            | Linear       | —     | —            | —      | (4, )                | 516       |
| Total parámetros entrenables: |              |       |              |        |                      | 6 446 756 |

Dado el desbalance descrito en la Sección II, la *Accuracy* puede ser engañosa, pues un modelo que ignore por completo la clase *no\_tumor* aún alcanzaría valores razonables. El **F1-Score macro** otorga el mismo peso a todas las clases sin considerar su frecuencia, por lo que penaliza explícitamente los modelos que descuidan las clases minoritarias. Por esta razón se adopta como métrica principal de comparación entre los tres modelos.

### III-B. Arquitectura Modelo 1 — CNN Baseline

La arquitectura del Modelo 1 fue diseñada como un *baseline* convolucional ligero, inspirado en la red OkanNet propuesta por Uçar y Kurt [?] y en la CNN desde cero de Gupta *et al.* [?]. Se compone de tres bloques convolucionales secuenciales seguidos de un cabezal denso, sin emplear *Batch Normalization* ni conexiones residuales, de modo que sirva como punto de referencia frente a los Modelos 2 y 3.

Las decisiones de diseño se justifican como sigue:

- **Tres bloques convolucionales** con filtros  $16 \rightarrow 32 \rightarrow 64$ , replicando la progresión geométrica de OkanNet [?]. Esta profundidad limitada deja margen explícito para que los Modelos 2 y 3 muestren mejoras atribuibles a su mayor complejidad.
- **Kernels**  $3 \times 3$  con *padding same* y **MaxPool**  $2 \times 2$  con *stride* 2: configuración estándar en la literatura de clasificación MRI [?] que preserva la información espacial dentro de cada bloque y la reduce a la mitad entre bloques.
- **Sin Batch Normalization**: decisión deliberada del enunciado, para aislar el efecto que introducirá el Modelo 2 al añadir BN.
- **Cabezal denso**:  $\text{Linear}(50\,176, 128) \rightarrow \text{ReLU} \rightarrow \text{Dropout}(0, 5) \rightarrow \text{Linear}(128, 4)$ . El *Dropout* en la única capa oculta del cabezal sigue la práctica de OkanNet [?] y mitiga el sobreajuste sin introducir regularización adicional.

- **Inicialización**: *Kaiming Normal* en las capas Conv2D (modo *fan\_out*) y en las capas Linear (modo *fan\_in*). Esta separación es crucial: una inicialización *fan\_out* aplicada a  $\text{Linear}(50\,176, 128)$  produciría una magnitud de preactivaciones tan elevada que rompería la convergencia, especialmente cuando se introduce BN.

El número total de parámetros entrenables es de 6 446 756, dominado casi en su totalidad ( $\approx 99,6\%$ ) por la primera capa totalmente conectada, lo cual es un patrón típico de arquitecturas tipo LeNet/AlexNet sin *Global Average Pooling*.

*Arquitectura comparativa OkanNet*: Como contraste académico se implementó una versión *réplica* de OkanNet [?], idéntica al Modelo 1 pero con *Batch Normalization 2D* añadido entre cada Conv2D y su ReLU. El total de parámetros asciende a 6 446 980 (+224 por las medias y varianzas aprendibles de BN), y los hiperparámetros de entrenamiento se mantienen idénticos al *baseline* para que la única variable que cambia entre ambas redes sea precisamente la presencia de BN.

### III-C. Arquitectura Modelo 2 — CNN Profunda o RNN

[PENDIENTE: descripción detallada del *model 2*, incluyendo el uso de *Batch Normalization* entre las capas convolucionales, *Dropout* en las capas densas, mayor profundidad (bloques convolucionales adicionales) y justificación de cada elemento frente al *baseline*.]

### III-D. Arquitectura Modelo 3 — MRIResNet con Atención SE

El Modelo 3, denominado **MRIResNet**, extiende el *baseline* en tres ejes: (i) un preprocesamiento multimodal de cinco canales que enriquece la representación de entrada, (ii) bloques residuales con conexiones *skip* que mitigan la degradación del gradiente en redes profundas, y (iii) módulos de atención *Squeeze-and-Excitation* (SE) [?] para la priorización adaptativa de características.

*Preprocesamiento multimodal (5 canales)*: En lugar de la representación RGB ( $B, 3, 224, 224$ ), el Modelo 3 recibe un tensor ( $B, 5, 224, 224$ ) generado mediante:

1. **Conversión RGB y redimensionado** a  $224 \times 224$ .
2. **CLAHE** (*Contrast Limited Adaptive Histogram Equalization*, *clipLimit*=2,0, *tileGrid*= $8 \times 8$ ): ecualización local del histograma con límite de contraste, que mejora la visibilidad de bordes tumorales sin amplificar el ruido global.
3. **Sobel**: gradiente espacial  $G = \sqrt{G_x^2 + G_y^2}$ , normalizado a  $[0, 1]$  y aplicado sobre la imagen CLAHE para maximizar la calidad de los bordes extraídos.
4. **Fusión**: concatenación de los canales  $[R, G, B, \text{CLAHE}, \text{Sobel}]$ .
5. **Normalización canal a canal** con estadísticos  $(\mu_c, \sigma_c)$  estimados sobre el conjunto *Training*.

Este diseño está conceptualmente inspirado en los hallazgos de Hubel y Wiesel [?] sobre la selectividad orientacional de

las neuronas de la corteza visual primaria, cuya sensibilidad a bordes y orientaciones motivó el diseño de los primeros filtros convolucionales aprendibles.

**Bloques residuales:** Cada bloque residual aprende la transformación  $\mathcal{F}(\mathbf{x}) + \mathbf{x}$  [?], con estructura interna: Conv(3×3)–BN–ReLU–Conv(3×3)–BN⊕x–ReLU. Cuando el número de canales entre entrada y salida difiere, el camino *skip* incorpora una proyección Conv(1×1)+BN para alinear dimensiones sin parámetros adicionales significativos.

**Módulo Squeeze-and-Excitation:** El módulo SE recalibra los canales en tres etapas:

1. **Squeeze:** *Global Average Pooling*  $z_c = \frac{1}{H \times W} \sum_{i,j} x_c(i, j) \rightarrow \text{descriptor } \mathbf{z} \in \mathbb{R}^C$ .
2. **Excitation:** FC–ReLU–FC–Sigmoid  $\rightarrow$  pesos por canal  $\mathbf{s} \in [0, 1]^C$ , con ratio de reducción  $r=8$ .
3. **Reescalado:**  $\hat{x}_c = s_c \cdot x_c$ , amplificando características relevantes y suprimiendo las irrelevantes.

Las decisiones de diseño se justifican como sigue:

- **Entrada de 5 canales:** la primera convolución acepta Conv2d(5, 32, 3) en lugar de 3 canales, procesando simultáneamente textura RGB, contraste local (CLAHE) y gradientes estructurales (Sobel).
- **Cuatro etapas residuales** con canales 32→64→128→256, siguiendo la progresión geométrica de ResNet [?]. Las tres primeras etapas aplican *MaxPool* 2×2; la cuarta preserva la resolución 14×14 para que el GAP agregue información espacial de mayor granularidad.
- **Global Average Pooling** reemplaza el cabezal Flatten→Linear(50176, 128) del Modelo 1, reduciendo los parámetros de 6,44M a 1,68M ( $\approx 74\%$  menos) y mejorando la robustez espacial.
- **Módulos SE con  $r=8$ :** el ratio garantiza al menos 4 unidades ocultas en las etapas de 32 canales (32/8=4), equilibrando capacidad expresiva y coste computacional.
- **Inicialización Kaiming:** idéntica al Modelo 1, con modo *fan\_out* para Conv2d y *fan\_in* para Linear.
- **Dropout (0,5)** aplicado únicamente en el cabezal, evitando interrumpir el flujo residual dentro de los bloques [?].

El total de parámetros entrenables es de 1676284, frente a los 6446756 del Modelo 1. La diferencia se debe exclusivamente al reemplazo del cabezal denso por GAP: el bloque convolucional resultante es considerablemente más profundo (4 etapas residuales vs. 3 bloques simples) pero paramétricamente más eficiente.

## IV. ENTRENAMIENTO E IMPLEMENTACIÓN

### IV-A. Hiperparámetros

La Tabla VI resume los hiperparámetros empleados para entrenar el Modelo 1 y su comparativa OkanNet. Para garantizar una comparación científicamente limpia, se mantienen idénticos en ambas arquitecturas; la única diferencia controlada entre ellas es la presencia de *Batch Normalization*.

El uso de *class\_weight* en la función de pérdida es un diferencial del presente trabajo frente a las referencias

revisadas [?], [?], ninguna de las cuales incorpora corrección explícita del desbalance de clases. Los pesos se calculan con la fórmula *balanced* de *scikit-learn*, inversamente proporcionales a la frecuencia de cada clase en *Training*.

El tiempo de entrenamiento sobre Apple Silicon con backend MPS fue de 7 min 44s para el Baseline y 3 min 39s para OkanNet, este último interrumpido por *early stopping* en la época 17.

### IV-B. Protocolo de Entrenamiento

La implementación se realiza íntegramente en **Python** con **PyTorch**, mediante *scripts* locales organizados en el directorio *src/*. El flujo de trabajo reproducible es el siguiente:

1. Crear un entorno virtual aislado: `python -m venv .venv` y activarlo.
2. Instalar dependencias: `pip install -r requirements.txt`.
3. Lanzar el entrenamiento de un modelo específico: `python src/models/train.py --model N --data_dir datasets/Training`, con  $N \in \{1, 2, 3\}$ .
4. Los *checkpoints* de pesos se almacenan en `outputs/results/` y las métricas por época se registran incrementalmente en `outputs/results/metrics.csv`.
5. La evaluación final sobre el conjunto de prueba se ejecuta con: `python src/models/evaluate.py --model N --data_dir datasets/Testing`.

Se aplica una división interna **80/20** sobre el conjunto *Training* para obtener un *validation set* usado en la monitorización de pérdida y métricas durante el entrenamiento y en la selección del mejor *checkpoint*. El conjunto *Testing* original se reserva como *holdout* independiente y solo se emplea en la evaluación final reportada en la sección de resultados.

### IV-C. Hiperparámetros Modelo 3

La Tabla VII resume los hiperparámetros empleados para entrenar el Modelo 3 (MRIResNet). Las diferencias más relevantes respecto al Modelo 1 son el uso de **AdamW** con *weight decay* desacoplado —en lugar de Adam sin regularización— y un *learning rate* inicial diez veces menor, coherente con la mayor profundidad de la red y la presencia de *Batch Normalization* en todos los bloques residuales.

La elección de **AdamW** frente a Adam responde a que el *weight decay* desacoplado de AdamW actúa como regularización  $L_2$  explícita independiente del *learning rate*, lo cual es especialmente beneficioso en redes con *Batch Normalization* [?]. El uso de *class\_weight* calculado con la fórmula *balanced* de *scikit-learn* se mantiene respecto al Modelo 1 para corregir el desbalance documentado en la Sección IV-A.

El protocolo de entrenamiento es análogo al descrito en la Sección IV-B: división 80/20, monitorización del F1-macro de validación para el *scheduler* y el *early stopping*, y registro de métricas por época en un archivo *.csv*.

Cuadro V: Arquitectura del Modelo 3 (MRIResNet). Entrada  $(B, 5, 224, 224)$ . ResBlock( $a \rightarrow b$ ): bloque residual con  $a$  canales de entrada y  $b$  de salida. SE: módulo Squeeze-and-Excitation con  $r=8$ .

| Etapas                        | Componentes                                                                   | Salida $(C, H, W)$ | Params    |
|-------------------------------|-------------------------------------------------------------------------------|--------------------|-----------|
| Inicial                       | Conv( $5 \rightarrow 32, 3 \times 3$ )+BN+ReLU+MaxPool                        | (32, 112, 112)     | 1 504     |
| Etapas 1                      | $2 \times [\text{ResBlock}(32 \rightarrow 32) + \text{SE}] + \text{MaxPool}$  | (32, 56, 56)       | 37 704    |
| Etapas 2                      | $2 \times [\text{ResBlock}(32 \rightarrow 64) + \text{SE}] + \text{MaxPool}$  | (64, 28, 28)       | 133 904   |
| Etapas 3                      | $2 \times [\text{ResBlock}(64 \rightarrow 128) + \text{SE}] + \text{MaxPool}$ | (128, 14, 14)      | 534 048   |
| Etapas 4                      | ResBlock( $128 \rightarrow 256$ )+SE                                          | (256, 14, 14)      | 935 712   |
| GAP                           | AdaptiveAvgPool2d(1)                                                          | (256, 1, 1)        | 0         |
| Cabezal                       | Linear( $256 \rightarrow 128$ )+ReLU+Drop(0,5)+Linear( $128 \rightarrow 4$ )  | (4, )              | 33 412    |
| Total parámetros entrenables: |                                                                               |                    | 1 676 284 |

Cuadro VI: Hiperparámetros del Modelo 1 (Baseline) y OkanNet.

| Hiperparámetro        | Baseline           | OkanNet            |
|-----------------------|--------------------|--------------------|
| Optimizador           | Adam               | Adam               |
| $(\beta_1, \beta_2)$  | (0,9, 0,999)       | (0,9, 0,999)       |
| Learning rate inicial | $1 \times 10^{-3}$ | $1 \times 10^{-3}$ |
| Scheduler             | ReduceLROnPlateau  | ReduceLROnPlateau  |
| factor / patience     | 0,5 / 3            | 0,5 / 3            |
| $\eta_{\min}$         | $1 \times 10^{-6}$ | $1 \times 10^{-6}$ |
| Función de pérdida    | CrossEntropyLoss   | CrossEntropyLoss   |
| con                   | class_weight       | class_weight       |
| Weight decay          | 0                  | 0                  |
| Batch size            | 32                 | 32                 |
| Epochs máx.           | 40                 | 40                 |
| Early stopping        | patience = 7       | patience = 7       |
| criterio              | F1-macro val.      | F1-macro val.      |
| Split train/val       | 80 % / 20 %        | 80 % / 20 %        |
| Seed                  | 42                 | 42                 |

Cuadro VII: Hiperparámetros del Modelo 3 (MRIResNet).

| Hiperparámetro         | MRIResNet (M3)            |
|------------------------|---------------------------|
| Optimizador            | AdamW                     |
| $(\beta_1, \beta_2)$   | (0,9, 0,999)              |
| Learning rate inicial  | $1 \times 10^{-4}$        |
| Weight decay           | $1 \times 10^{-4}$        |
| Scheduler              | ReduceLROnPlateau         |
| factor / patience      | 0,5 / 5                   |
| $\eta_{\min}$          | $1 \times 10^{-6}$        |
| Función de pérdida     | CrossEntropyLoss          |
| con                    | class_weight              |
| Batch size             | 32                        |
| Epochs máx.            | 50                        |
| Early stopping         | patience = 10             |
| criterio               | F1-macro val.             |
| Split train/val        | 80 % / 20 %               |
| Seed                   | 42                        |
| Canales de entrada     | 5 (R, G, B, CLAHE, Sobel) |
| Parámetros entrenables | 1 676 284                 |

Cuadro VIII: Métricas globales sobre *Testing* (holdout de 394 imágenes).

| Modelo          | Accuracy | Precision | Recall | F1-Macro      |
|-----------------|----------|-----------|--------|---------------|
| Baseline (M1)   | 0,6751   | 0,7443    | 0,6508 | <b>0,6252</b> |
| OkanNet (comp.) | 0,4467   | 0,4901    | 0,4634 | 0,4233        |
| Modelo 2        | —        | —         | —      | —             |
| MRIResNet (M3)  | —        | —         | —      | —             |

## V. RESULTADOS

### V-A. Métricas por Modelo

La Tabla VIII reporta las métricas globales sobre el conjunto de prueba *Testing* (holdout oficial de 394 imágenes) para el Modelo 1 (CNN Baseline) y la arquitectura comparativa OkanNet. Las métricas de los Modelos 2 y 3 se reportan en sus respectivas entregas.

**Discusión.** El Modelo 1 alcanza un F1-Macro de 0,6252 sobre el *holdout*, mientras que durante el entrenamiento la métrica de validación alcanzó un máximo de 0,9231 en la época 33. La diferencia de aproximadamente 30 puntos entre validación y prueba refleja la distribución no uniforme entre los conjuntos *Training* y *Testing* del dataset Sartaj Bhuvaji, un patrón documentado en la literatura del corpus y conocido como *distribution shift* entre las particiones oficiales.

Contrariamente a lo esperado, la incorporación de *Batch Normalization* (OkanNet) reduce el F1-Macro de 0,6252 a 0,4233 bajo los mismos hiperparámetros, una caída de 20,19 puntos porcentuales. Este resultado, lejos de invalidar BN como técnica, sugiere que su efectividad depende de un régimen de hiperparámetros propio (en particular, *batch size* mayor y posiblemente un *learning rate* adaptado), lo cual se discute en mayor profundidad en la Sección ??.

### V-B. Análisis por Clase

La Tabla IX desglosa el F1-Score por clase sobre el conjunto *Testing*.

**Discusión.** Los resultados por clase **invalidan la hipótesis formulada en la Sección II**, según la cual *meningioma\_tumor* sería la clase más difícil debido a la similitud visual de sus patrones con otras lesiones intracraneales. Empíricamente se observa lo contrario: *meningioma\_tumor* alcanza un F1 de

Cuadro IX: F1-Score por clase sobre *Testing*.

| Clase            | Baseline (M1) | OkanNet | M2 | MRIResNet (l) |
|------------------|---------------|---------|----|---------------|
| glioma_tumor     | 0,3307        | 0,2597  | —  | —             |
| meningioma_tumor | 0,7766        | 0,2517  | —  | —             |
| no_tumor         | 0,7445        | 0,5337  | —  | —             |
| pituitary_tumor  | 0,6491        | 0,6479  | —  | —             |




Figura 9: Matriz de confusión normalizada del Modelo 1 (Baseline) sobre *Testing*. Los valores en la diagonal corresponden al Recall por clase.

0,7766 (segunda mejor clase), mientras que *glioma\_tumor* resulta ser la clase con peor rendimiento, con F1 de 0,3307.

Un análisis más detallado de las métricas de Precision y Recall del Modelo 1 sobre *glioma\_tumor* arroja luz sobre la naturaleza del error: la Precision es alta (0,7778) pero el Recall es bajísimo (0,2100). Esto indica que, cuando el modelo predice *glioma*, suele acertar; pero solo identifica como tales al 21 % de los gliomas reales. El restante 79 % se desvía hacia otras clases, principalmente *meningioma\_tumor*, cuyo Recall de 0,9217 sugiere que está actuando como “clase por defecto” para casos ambiguos. Este patrón no responde a una dificultad intrínseca del glioma sino a un sesgo del modelo en la frontera de decisión, agravado por el desbalance original del dataset.

El hallazgo es relevante para los Modelos 2 y 3: estrategias como *Batch Normalization* con régimen propio, *Focal Loss* o arquitecturas con mayor capacidad de representación discriminativa serían las direcciones esperadas para corregir este desbalance de Recall por clase.

#### V-C. Matrices de Confusión

Las Figuras 9 y 10 muestran las matrices de confusión normalizadas sobre el conjunto *Testing* para el Modelo 1 y OkanNet respectivamente.

**Patrones observados.** En el Modelo 1, el patrón de error dominante es la confusión *glioma* → *meningioma*: aproxima-




Figura 10: Matriz de confusión normalizada de OkanNet (comparativa) sobre *Testing*.

damente el 79 % de los gliomas reales se clasifican erróneamente, en su mayoría como meningioma, lo cual coincide con el análisis de Recall reportado en la Sección V-B. La clase *no\_tumor* se identifica correctamente en  $\approx 97$  % de los casos, consistente con la diferencia fotométrica clara documentada en el EDA.

En OkanNet, las confusiones se distribuyen más uniformemente entre todas las clases, reflejando la falta de convergencia del modelo bajo el régimen de hiperparámetros impuesto. Las clases *glioma\_tumor* y *meningioma\_tumor* muestran patrones de error particularmente erráticos.

#### V-D. Curvas de Entrenamiento

La Figura 11 muestra la evolución de *loss*, *accuracy*, F1-macro y *learning rate* por época durante el entrenamiento del Modelo 1.

**Análisis de convergencia.** El Baseline alcanza su mejor F1-macro de validación (0,9231) en la época 33 y agota el presupuesto máximo de 40 épocas sin disparar el *early stopping*, lo que sugiere que el modelo aún no había convergido completamente y podría beneficiarse de un entrenamiento más prolongado o de un *scheduler* de *learning rate* más agresivo.

En contraste, OkanNet exhibe convergencia inestable desde el inicio (*train loss* inicial de 4,77, vs. 1,03 del Baseline) y dispara el *early stopping* en la época 17, alcanzando un F1-macro máximo de validación de solo 0,6542. El *scheduler* ReduceLROnPlateau reduce el *learning rate* en varias ocasiones durante el entrenamiento de OkanNet sin lograr estabilizar la métrica de validación. Este comportamiento es consistente con la sensibilidad conocida de *Batch Normalization* al tamaño de *batch* y a la magnitud del *learning rate*: con  $\text{batch} = 32$  y  $\text{lr} = 10^{-3}$ , BN amplifica el ruido de las estadísticas por *mini-batch*, perjudicando la convergencia.




Figura 11: Curvas de entrenamiento del Modelo 1 (Baseline): pérdida, accuracy, F1-macro y *learning rate* en función de la época.




Figura 12: Curvas de entrenamiento de OkanNet (comparativa). Nótese la convergencia inestable y el disparo del *early stopping* en la época 17.




Figura 13: Comparación del F1-Macro de validación entre Baseline y OkanNet a lo largo del entrenamiento.

La Figura 13 sintetiza visualmente este contraste: el Baseline mantiene una trayectoria de mejora monótona, mientras




Figura 14: Matriz de confusión normalizada del Modelo 3 (MRIResNet) sobre *Testing*. Los valores en la diagonal corresponden al Recall por clase.

que OkanNet oscila y converge a un máximo sustancialmente inferior.

#### V-E. Resultados Modelo 3 — MRIResNet

**Métricas globales:** Las métricas sobre el conjunto *Testing* para el Modelo 3 (MRIResNet) se reportan en la Tabla VIII. El modelo cuenta con 1 676 284 parámetros entrenables, aproximadamente el 26 % del total del Modelo 1, gracias al reemplazo del cabezal denso por *Global Average Pooling*.

**Discusión.** El MRIResNet introduce tres mejoras estructurales respecto al *baseline*: preprocesamiento multimodal de 5 canales (CLAHE + Sobel), aprendizaje residual y atención SE. La hipótesis de trabajo es que la representación explícita de bordes y contraste local favorece la discriminación entre las clases más difíciles (*glioma* y *meningioma*), cuya confusión era el error dominante del Modelo 1.

**Análisis por clase:** La Tabla IX desglosa el F1-Score por clase del Modelo 3 sobre *Testing*. Se espera que el canal Sobel mejore especialmente el Recall de *glioma\_tumor*, cuya baja sensibilidad en el Modelo 1 (0,2100) se atribuía a la debilidad de sus bordes en la representación RGB. La atención SE, al ponderar los canales de forma dinámica, debería reforzar la señal de los canales CLAHE y Sobel cuando estos son diagnósticamente relevantes.

**Matriz de confusión:** La Figura 14 muestra la matriz de confusión del Modelo 3. El patrón de interés clave es la frontera de decisión *glioma*–*meningioma*: si el preprocesamiento multimodal y la atención SE son efectivos, se espera observar una reducción del flujo de error *glioma*→*meningioma* respecto a la Figura 9.

**Curvas de entrenamiento: Análisis de convergencia.** La Figura 15 muestra la evolución del entrenamiento del Modelo 3. La combinación de AdamW ( $lr=10^{-4}$ ) con *Batch*




Figura 15: Curvas de entrenamiento del Modelo 3 (MRIRes-Net): pérdida, *accuracy*, F1-macro y *learning rate* en función de la época.

*Normalization* en todos los bloques residuales persigue una convergencia más estable que la observada en OkanNet bajo el régimen de  $lr=10^{-3}$  sin *weight decay*. El *early stopping* con paciencia 10 otorga al modelo mayor margen para explorar antes de interrumpir el entrenamiento, consistente con la mayor profundidad de la red.

## VI. CONCLUSIONES

[PENDIENTE: discusión final estructurada en cuatro ejes: (i) si los resultados obtenidos por las CNN propias permiten considerar el sistema como una herramienta de apoyo diagnóstico clínicamente confiable; (ii) análisis de las clases problemáticas y sus posibles causas (similitud fotométrica, desbalance, variabilidad intra-clase); (iii) limitaciones del enfoque sin *transfer learning* y comparación cualitativa con literatura que sí lo emplea; y (iv) trabajo futuro, incluyendo *transfer learning* desde redes preentrenadas, segmentación previa de la región de interés, ampliación del dataset y validación con datos clínicos externos.]