

Clasificación de Tumores Cerebrales en MRI mediante Redes Neuronales Convolucionales propias sobre el Dataset *Brain Tumor Classification MRI*

Abel Albuez Sánchez, Daniel Rios, Juan Torres y Javier Esquivel
Maestría en Analítica para Inteligencia de Negocios (MAIN)
Pontificia Universidad Javeriana, Bogotá D.C., Colombia
Profesor: Julio Omar Palacio Niño, M.Sc. Aprendizaje Profundo 2026

Resumen—La clasificación automática de tumores cerebrales en imágenes de resonancia magnética (MRI) constituye una tarea relevante para el apoyo al diagnóstico radiológico. Este trabajo aborda la clasificación de cuatro categorías —*glioma*, *meningioma*, *pituitary* y *no tumor*— sobre el dataset público *Brain Tumor Classification MRI* de Kaggle (3 264 imágenes), mediante tres arquitecturas propias de redes neuronales convolucionales (CNN) entrenadas desde cero, sin emplear *transfer learning*. Se reporta un análisis exploratorio detallado del dataset —incluyendo distribución por clases, dimensionalidad y estadísticos de intensidad—, un pipeline de preprocesamiento con normalización tipo ImageNet y *data augmentation*, y un protocolo de evaluación basado en *F1-Score* macro, adecuado para escenarios con desbalance de clases.

Index Terms—clasificación de tumores cerebrales, redes neuronales convolucionales, resonancia magnética, aprendizaje profundo, PyTorch, *F1-Score* macro

I. OBJETIVO DEL PROYECTO

I-A. Contexto Clínico

El diagnóstico temprano y preciso de tumores cerebrales constituye uno de los retos más relevantes de la neuro-oncología contemporánea. La resonancia magnética (MRI, *Magnetic Resonance Imaging*) es la modalidad de imagen de referencia para la detección y caracterización de estas lesiones; sin embargo, su interpretación depende fuertemente de la experiencia del radiólogo y está sujeta a variabilidad inter-observador. En este contexto, los sistemas de apoyo al diagnóstico basados en aprendizaje profundo han mostrado resultados prometedores como herramientas de cribado y segunda opinión, capaces de procesar grandes volúmenes de estudios de manera consistente.

I-B. Objetivo Técnico

El presente proyecto tiene como objetivo diseñar, entrenar y evaluar tres arquitecturas propias de redes neuronales convolucionales (CNN) para la clasificación automática de imágenes MRI cerebrales en cuatro categorías: *glioma_tumor*, *meningioma_tumor*, *no_tumor* y *pituitary_tumor*. Se utiliza el dataset público *Brain Tumor Classification MRI* disponible en Kaggle. De manera explícita, este trabajo **no** emplea técnicas de *transfer learning* ni pesos preentrenados sobre ImageNet u otros corpus; el énfasis pedagógico está en la construcción de arquitecturas convolucionales desde cero y en la comprensión del impacto de sus hiperparámetros y bloques constitutivos.

Cuadro I: Distribución de imágenes por clase y partición.

Clase	Train	Test	Total
glioma_tumor	826	100	926
meningioma_tumor	822	115	937
no_tumor	395	105	500
pituitary_tumor	827	74	901
Total	2 870	394	3 264

I-C. Criterios de Evaluación

La evaluación de los modelos se realizará mediante un conjunto de métricas clásicas de clasificación multiclase: *Accuracy*, *Precision*, *Recall* y *F1-Score* en su variante *macro-averaged*, complementadas con la matriz de confusión por modelo. Dado el desbalance entre clases observado durante el análisis exploratorio (Sección II), el *F1-macro* se adopta como métrica principal de comparación, por su robustez frente a clases minoritarias.

II. ANÁLISIS DEL DATASET Y DIMENSIONALIDAD

II-A. Descripción del Dataset

El conjunto de datos *Brain Tumor Classification MRI*, publicado en Kaggle, contiene **3 264 imágenes** de resonancia magnética cerebral organizadas en cuatro clases diagnósticas: *glioma_tumor*, *meningioma_tumor*, *pituitary_tumor* y *no_tumor* (estudios sin hallazgos tumorales). Los autores del dataset proporcionan una partición oficial entre conjuntos de entrenamiento y prueba que se respeta en este trabajo. La Tabla I resume su distribución.

El conjunto de entrenamiento concentra el **87,9 %** de las imágenes (2 870), mientras que el conjunto de prueba representa el **12,1 %** restante (394 imágenes). El conjunto *Testing* se reserva como *holdout* independiente para la evaluación final de los modelos, y la subdivisión interna para validación se realiza únicamente sobre *Training* (véase Sección IV-B).

II-B. Balance de Clases

El análisis de balance evidencia que la clase *no_tumor* es la minoritaria en entrenamiento, con aproximadamente **395** imágenes, frente a **~825** para cada una de las tres clases tumorales. Esta proporción asimétrica ($\sim 1:2$) puede inducir




Figura 1: Distribución absoluta por clase y partición.




Figura 2: Proporción relativa en entrenamiento.

sesgos durante el aprendizaje, llevando al modelo a sub-representar la clase minoritaria y a inflar artificialmente la *Accuracy* global.

Como estrategia de compensación se adopta el uso de pesos por clase (*class_weight*) en la función de pérdida *Cross-Entropy*, con ponderaciones inversamente proporcionales a la frecuencia relativa de cada clase en el conjunto de entrenamiento. Esto incrementa la magnitud del gradiente para errores cometidos sobre la clase minoritaria sin alterar la distribución de muestras observadas. Las Figuras 1 y 2 ilustran gráficamente esta distribución.

II-C. Análisis de Dimensionalidad

Se inspeccionó una muestra de **80 imágenes por clase** para caracterizar la variabilidad en resolución espacial del dataset. Las imágenes presentan resoluciones altamente heterogéneas: las dimensiones máximas observadas alcanzan **1024×768 px** y las mínimas **59×80 px**. La relación de aspecto también varía considerablemente entre estudios, reflejo de las diferencias entre equipos de adquisición y protocolos clínicos.

Dada esta heterogeneidad, se establece el redimensionamiento uniforme a **224×224 px** como paso obligatorio del pipeline. Esta resolución constituye un compromiso adecuado entre el nivel de detalle anatómico preservado y el costo computacional, y es además el formato canónico de las arquitecturas CNN modernas, lo que facilita comparaciones posteriores. Las Figuras 3 y 4 muestran respectivamente el histograma de resoluciones y la distribución de relaciones de aspecto observadas por clase.

II-D. Análisis Estadístico de Intensidades

Se analizaron las distribuciones de intensidad de píxeles (escala de grises) y canales RGB por clase, con el fin de identificar diferencias fotométricas potencialmente discriminativas para el modelado. La Tabla II resume los estadísticos descriptivos.




Figura 3: Histograma de resoluciones (ancho × alto) en el dataset.




Figura 4: Distribución de relaciones de aspecto por clase.

Cuadro II: Estadísticas de intensidad (escala 0–255) por clase.

Clase	Media	Std	Mín	Máx	Mediana
glioma_tumor	36,23	41,43	0	255	14
meningioma_tumor	44,56	47,77	0	255	28
no_tumor	52,21	59,63	0	255	22
pituitary_tumor	49,50	42,94	0	255	50

Los *gliomas* presentan los valores más bajos de media (36,23) y mediana (14), lo que los caracteriza como tejidos relativamente **hipointensos** en la modalidad analizada. Los tumores *pituitarios*, en contraste, presentan la mediana más alta (50) y la menor dispersión relativa, indicando intensidades más concentradas y homogéneas. La clase *no_tumor* muestra la mayor desviación estándar (59,63), consistente con la variedad anatómica del cerebro sano sin focalización lesional. Estas diferencias fotométricas constituyen señales útiles que una CNN puede explotar a nivel de filtros convolucionales de bajo nivel.

Para estabilizar el entrenamiento se aplicará normalización *Z-score* sobre los tres canales utilizando los estadísticos canónicos de ImageNet ($\mu = [0,485, 0,456, 0,406]$, $\sigma = [0,229, 0,224, 0,225]$), valores ampliamente adoptados en la literatura como referencia robusta incluso cuando no se emplea *transfer learning*. Las Figuras 5 y 6 complementan visualmente este análisis.

II-E. Imagen Promedio y Muestras por Clase

La Figura 7 presenta la imagen promedio por clase, calculada como la media píxel a píxel de 100 imágenes redimensionadas a 224×224 px. Los gliomas exhiben regiones **hipointensas difusas**, de bordes poco definidos, consistente con su naturaleza infiltrativa. Los tumores *pituitarios* tienden a concentrarse en la zona central, reflejando la ubicación anatómica de la glándula hipófisis. Los meningiomas muestran




Figura 5: Diagramas de caja de intensidades de píxel por clase.




Figura 6: Distribución de intensidades por canal RGB y por clase.




Figura 7: Imagen promedio por clase (100 imgs, 224×224 px).

patrones intermedios con tendencia a localizarse en la periferia. La clase *no_tumor*, al promediar tejidos cerebrales sanos en distintas orientaciones, produce una imagen más difusa y centralmente simétrica.

La Figura 8 ilustra cinco ejemplos representativos por clase. Se evidencia alta variabilidad intra-clase en orientación, escala y contraste, lo que justifica el uso de *data augmentation* —rotación $\pm 15^\circ$, *flip* horizontal y variación de brillo— durante el entrenamiento para mejorar la capacidad de generalización




Figura 8: 5 muestras por clase — *Training*.

Cuadro III: Pipeline de preprocesamiento propuesto.

#	Paso	Justificación
1	Resize 224×224 px	Resoluciones heterogéneas requieren entrada uniforme.
2	Conversión a RGB	Algunas imágenes en escala de grises; se unifica formato.
3	Z-score (μ ImageNet)	Estabiliza el gradiente y mejora la convergencia.
4	<i>Data augmentation</i>	Rotación $\pm 15^\circ$, <i>flip</i> horizontal y variación de brillo.
5	<i>class_weight</i>	Compensa el desbalance de <i>no_tumor</i> .
6	Split 80/20 Training	Separa validación sin contaminar el <i>holdout</i> oficial.

del modelo.

II-F. Plan de Preprocesamiento

A partir de los hallazgos anteriores, se define el pipeline de preprocesamiento resumido en la Tabla III, aplicado de forma consistente a las tres arquitecturas evaluadas.

III. METODOLOGÍA

III-A. Métricas de Evaluación

Para evaluar las arquitecturas propuestas se emplea un conjunto de métricas estándar de clasificación multiclase:

- **Accuracy:** proporción global de aciertos, $\text{Acc} = (TP + TN) / (TP + TN + FP + FN)$.
- **Precision (macro):** promedio no ponderado de la precisión por clase, $\frac{1}{C} \sum_c TP_c / (TP_c + FP_c)$.
- **Recall (macro):** promedio no ponderado de la sensibilidad por clase, $\frac{1}{C} \sum_c TP_c / (TP_c + FN_c)$.
- **F1-Score (macro):** media armónica de Precision y Recall, $F1 = 2 \cdot P \cdot R / (P + R)$, calculada por clase y promediada de forma no ponderada.
- **Matriz de confusión:** análisis cualitativo de los errores entre pares de clases.

Cuadro IV: Arquitectura del Modelo 1 (CNN Baseline). Entrada ($B, 3, 224, 224$).

#	Capa	Filt.	Kernel	Stride	Salida (C, H, W)	Params
1	Conv2D	16	3×3	1	(16, 224, 224)	448
2	ReLU	—	—	—	(16, 224, 224)	0
3	MaxPool2D	—	2×2	2	(16, 112, 112)	0
4	Conv2D	32	3×3	1	(32, 112, 112)	4 640
5	ReLU	—	—	—	(32, 112, 112)	0
6	MaxPool2D	—	2×2	2	(32, 56, 56)	0
7	Conv2D	64	3×3	1	(64, 56, 56)	18 496
8	ReLU	—	—	—	(64, 56, 56)	0
9	MaxPool2D	—	2×2	2	(64, 28, 28)	0
10	Flatten	—	—	—	(50 176,)	0
11	Linear	—	—	—	(128,)	6 422 656
12	ReLU	—	—	—	(128,)	0
13	Dropout(0.5)	—	—	—	(128,)	0
14	Linear	—	—	—	(4,)	516
Total parámetros entrenables:						6 446 756

Dado el desbalance descrito en la Sección II, la *Accuracy* puede ser engañosa, pues un modelo que ignore por completo la clase *no_tumor* aún alcanzaría valores razonables. El **F1-Score macro** otorga el mismo peso a todas las clases sin considerar su frecuencia, por lo que penaliza explícitamente los modelos que descuidan las clases minoritarias. Por esta razón se adopta como métrica principal de comparación entre los tres modelos.

III-B. Arquitectura Modelo 1 — CNN Baseline

La arquitectura del Modelo 1 fue diseñada como un *baseline* convolucional ligero, inspirado en la red OkanNet propuesta por Uçar y Kurt [?] y en la CNN desde cero de Gupta *et al.* [?]. Se compone de tres bloques convolucionales secuenciales seguidos de un cabezal denso, sin emplear *Batch Normalization* ni conexiones residuales, de modo que sirva como punto de referencia frente a los Modelos 2 y 3.

Las decisiones de diseño se justifican como sigue:

- **Tres bloques convolucionales** con filtros 16→32→64, replicando la progresión geométrica de OkanNet [?]. Esta profundidad limitada deja margen explícito para que los Modelos 2 y 3 muestren mejoras atribuibles a su mayor complejidad.
- **Kernels** 3×3 con *padding same* y **MaxPool** 2×2 con *stride* 2: configuración estándar en la literatura de clasificación MRI [?] que preserva la información espacial dentro de cada bloque y la reduce a la mitad entre bloques.
- **Sin Batch Normalization**: decisión deliberada del enunciado, para aislar el efecto que introducirá el Modelo 2 al añadir BN.
- **Cabezal denso**: $\text{Linear}(50\,176, 128) \rightarrow \text{ReLU} \rightarrow \text{Dropout}(0, 5) \rightarrow \text{Linear}(128, 4)$. El *Dropout* en la única capa oculta del cabezal sigue la práctica de OkanNet [?] y mitiga el sobreajuste sin introducir regularización adicional.

- **Inicialización**: *Kaiming Normal* en las capas Conv2D (modo *fan_out*) y en las capas Linear (modo *fan_in*). Esta separación es crucial: una inicialización *fan_out* aplicada a $\text{Linear}(50\,176, 128)$ produciría una magnitud de preactivaciones tan elevada que rompería la convergencia, especialmente cuando se introduce BN.

El número total de parámetros entrenables es de 6 446 756, dominado casi en su totalidad ($\approx 99,6\%$) por la primera capa totalmente conectada, lo cual es un patrón típico de arquitecturas tipo LeNet/AlexNet sin *Global Average Pooling*.

Arquitectura comparativa OkanNet: Como contraste académico se implementó una versión *réplica* de OkanNet [?], idéntica al Modelo 1 pero con *Batch Normalization 2D* añadido entre cada Conv2D y su ReLU. El total de parámetros asciende a 6 446 980 (+224 por las medias y varianzas aprendibles de BN), y los hiperparámetros de entrenamiento se mantienen idénticos al *baseline* para que la única variable que cambia entre ambas redes sea precisamente la presencia de BN.

III-C. Arquitectura Modelo 2 — CNN Profunda

[PENDIENTE: descripción detallada del *model 2*, incluyendo el uso de *Batch Normalization* entre las capas convolucionales, *Dropout* en las capas densas, mayor profundidad (bloques convolucionales adicionales) y justificación de cada elemento frente al *baseline*.]

III-D. Arquitectura Modelo 3 — CNN con Técnica Avanzada

[PENDIENTE: descripción del *model 3*, integrando una técnica avanzada construida desde cero (por ejemplo, bloques residuales tipo ResNet, *Global Average Pooling*, módulos de atención o conexiones densas), manteniendo la restricción de no usar pesos preentrenados.]

IV. ENTRENAMIENTO E IMPLEMENTACIÓN

IV-A. Hiperparámetros

La Tabla V resume los hiperparámetros empleados para entrenar el Modelo 1 y su comparativa OkanNet. Para garantizar una comparación científicamente limpia, se mantienen idénticos en ambas arquitecturas; la única diferencia controlada entre ellas es la presencia de *Batch Normalization*.

El uso de *class_weight* en la función de pérdida es un diferencial del presente trabajo frente a las referencias revisadas [?], [?], ninguna de las cuales incorpora corrección explícita del desbalance de clases. Los pesos se calculan con la fórmula *balanced* de *scikit-learn*, inversamente proporcionales a la frecuencia de cada clase en *Training*.

El tiempo de entrenamiento sobre Apple Silicon con backend MPS fue de 7 min 44s para el Baseline y 3 min 39s para OkanNet, este último interrumpido por *early stopping* en la época 17.

Cuadro V: Hiperparámetros del Modelo 1 (Baseline) y OkanNet.

Hiperparámetro	Baseline	OkanNet
Optimizador	Adam	Adam
(β_1, β_2)	(0,9, 0,999)	(0,9, 0,999)
Learning rate inicial	1×10^{-3}	1×10^{-3}
Scheduler	ReduceLROnPlateau	ReduceLROnPlateau
factor / patience	0,5 / 3	0,5 / 3
$\eta_{\min}$	1×10^{-6}	1×10^{-6}
Función de pérdida	CrossEntropyLoss	CrossEntropyLoss
con	class_weight	class_weight
Weight decay	0	0
Batch size	32	32
Epochs máx.	40	40
Early stopping	patience = 7	patience = 7
criterio	F1-macro val.	F1-macro val.
Split train/val	80 % / 20 %	80 % / 20 %
Seed	42	42

IV-B. Protocolo de Entrenamiento

La implementación se realiza íntegramente en **Python** con **PyTorch**, mediante *scripts* locales organizados en el directorio `src/`. El flujo de trabajo reproducible es el siguiente:

1. Crear un entorno virtual aislado: `python -m venv .venv` y activarlo.
2. Instalar dependencias: `pip install -r requirements.txt`.
3. Lanzar el entrenamiento de un modelo específico: `python src/models/train.py --model N --data_dir datasets/Training`, con $N \in \{1, 2, 3\}$.
4. Los *checkpoints* de pesos se almacenan en `outputs/results/` y las métricas por época se registran incrementalmente en `outputs/results/metrics.csv`.
5. La evaluación final sobre el conjunto de prueba se ejecuta con:
`python src/models/evaluate.py --model N --data_dir datasets/Testing`.

Se aplica una división interna **80/20** sobre el conjunto *Training* para obtener un *validation set* usado en la monitorización de pérdida y métricas durante el entrenamiento y en la selección del mejor *checkpoint*. El conjunto *Testing* original se reserva como *holdout* independiente y solo se emplea en la evaluación final reportada en la sección de resultados.

V. RESULTADOS

V-A. Métricas por Modelo

La Tabla VI reporta las métricas globales sobre el conjunto de prueba *Testing* (*holdout* oficial de 394 imágenes) para el Modelo 1 (CNN Baseline) y la arquitectura comparativa OkanNet. Las métricas de los Modelos 2 y 3 se reportan en sus respectivas entregas.

Cuadro VI: Métricas globales sobre *Testing* (*holdout* de 394 imágenes). *Modelos 2 y 3 pendientes de entrega*.

Modelo	Accuracy	Precision	Recall	F1-Macro
Baseline (M1)	0,6751	0,7443	0,6508	0,6252
OkanNet (comp.)	0,4467	0,4901	0,4634	0,4233
Modelo 2	—	—	—	—
Modelo 3	—	—	—	—

Cuadro VII: F1-Score por clase sobre *Testing*. *Modelos 2 y 3 pendientes de entrega*.

Clase	Baseline (M1)	OkanNet
glioma_tumor	0,3307	0,2597
meningioma_tumor	0,7766	0,2517
no_tumor	0,7445	0,5337
pituitary_tumor	0,6491	0,6479

Discusión. El Modelo 1 alcanza un F1-Macro de 0,6252 sobre el *holdout*, mientras que durante el entrenamiento la métrica de validación alcanzó un máximo de 0,9231 en la época 33. La diferencia de aproximadamente 30 puntos entre validación y prueba refleja la distribución no uniforme entre los conjuntos *Training* y *Testing* del dataset Sartaj Bhuvaji, un patrón documentado en la literatura del corpus y conocido como *distribution shift* entre las particiones oficiales.

Contrariamente a lo esperado, la incorporación de *Batch Normalization* (OkanNet) reduce el F1-Macro de 0,6252 a 0,4233 bajo los mismos hiperparámetros, una caída de 20,19 puntos porcentuales. Este resultado, lejos de invalidar BN como técnica, sugiere que su efectividad depende de un régimen de hiperparámetros propio (en particular, *batch size* mayor y posiblemente un *learning rate* adaptado), lo cual se discute en mayor profundidad en la Sección ??.

V-B. Análisis por Clase

La Tabla VII desglosa el F1-Score por clase sobre el conjunto *Testing*.

Discusión. Los resultados por clase **invalidan la hipótesis formulada en la Sección II**, según la cual *meningioma_tumor* sería la clase más difícil debido a la similitud visual de sus patrones con otras lesiones intracraneales. Empíricamente se observa lo contrario: *meningioma_tumor* alcanza un F1 de 0,7766 (segunda mejor clase), mientras que *glioma_tumor* resulta ser la clase con peor rendimiento, con F1 de 0,3307.

Un análisis más detallado de las métricas de Precision y Recall del Modelo 1 sobre *glioma_tumor* arroja luz sobre la naturaleza del error: la Precision es alta (0,7778) pero el Recall es bajísimo (0,2100). Esto indica que, cuando el modelo predice *glioma*, suele acertar; pero solo identifica como tales al 21 % de los gliomas reales. El restante 79 % se desvía hacia otras clases, principalmente *meningioma_tumor*, cuyo Recall de 0,9217 sugiere que está actuando como “clase por defecto” para casos ambiguos. Este patrón no responde a una dificultad intrínseca del glioma sino a un sesgo del modelo en la frontera de decisión, agravado por el desbalance original del dataset.




Figura 9: Matriz de confusión normalizada del Modelo 1 (Baseline) sobre *Testing*. Los valores en la diagonal corresponden al Recall por clase.




Figura 10: Matriz de confusión normalizada de OkanNet (comparativa) sobre *Testing*.

El hallazgo es relevante para los Modelos 2 y 3: estrategias como *Batch Normalization* con régimen propio, *Focal Loss* o arquitecturas con mayor capacidad de representación discriminativa serían las direcciones esperadas para corregir este desbalance de Recall por clase.

V-C. Matrices de Confusión

Las Figuras 9 y 10 muestran las matrices de confusión normalizadas sobre el conjunto *Testing* para el Modelo 1 y OkanNet respectivamente.




Figura 11: Curvas de entrenamiento del Modelo 1 (Baseline): pérdida, accuracy, F1-macro y learning rate en función de la época.

Patrones observados. En el Modelo 1, el patrón de error dominante es la confusión *glioma* $\rightarrow$ *meningioma*: aproximadamente el 79 % de los gliomas reales se clasifican erróneamente, en su mayoría como meningioma, lo cual coincide con el análisis de Recall reportado en la Sección V-B. La clase *no_tumor* se identifica correctamente en ≈ 97 % de los casos, consistente con la diferencia fotométrica clara documentada en el EDA.

En OkanNet, las confusiones se distribuyen más uniformemente entre todas las clases, reflejando la falta de convergencia del modelo bajo el régimen de hiperparámetros impuesto. Las clases *glioma_tumor* y *meningioma_tumor* muestran patrones de error particularmente erráticos.

V-D. Curvas de Entrenamiento

La Figura 11 muestra la evolución de *loss*, *accuracy*, F1-macro y *learning rate* por época durante el entrenamiento del Modelo 1.

Análisis de convergencia. El Baseline alcanza su mejor F1-macro de validación (0,9231) en la época 33 y agota el presupuesto máximo de 40 épocas sin disparar el *early stopping*, lo que sugiere que el modelo aún no había convergido completamente y podría beneficiarse de un entrenamiento más prolongado o de un *scheduler* de *learning rate* más agresivo.

En contraste, OkanNet exhibe convergencia inestable desde el inicio (*train loss* inicial de 4,77, vs. 1,03 del Baseline) y dispara el *early stopping* en la época 17, alcanzando un F1-macro máximo de validación de solo 0,6542. El *scheduler* *ReduceLROnPlateau* reduce el *learning rate* en varias ocasiones durante el entrenamiento de OkanNet sin lograr estabilizar la métrica de validación. Este comportamiento es consistente con la sensibilidad conocida de *Batch Normalization* al tamaño de *batch* y a la magnitud del *learning rate*: con *batch* = 32 y *lr* = 10^{-3} , BN amplifica el ruido de las estadísticas por *mini-batch*, perjudicando la convergencia.




Figura 12: Curvas de entrenamiento de OkanNet (comparativa). Nótese la convergencia inestable y el disparo del *early stopping* en la época 17.




Figura 13: Comparación del F1-Macro de validación entre Baseline y OkanNet a lo largo del entrenamiento.

La Figura 13 sintetiza visualmente este contraste: el Baseline mantiene una trayectoria de mejora monótona, mientras que OkanNet oscila y converge a un máximo sustancialmente inferior.

VI. CONCLUSIONES

[PENDIENTE: discusión final estructurada en cuatro ejes: (i) si los resultados obtenidos por las CNN propias permiten considerar el sistema como una herramienta de apoyo diagnóstico clínicamente confiable; (ii) análisis de las clases problemáticas y sus posibles causas (similitud fotométrica, desbalance, variabilidad intra-clase); (iii) limitaciones del enfoque sin transfer learning y comparación cualitativa con literatura que sí lo emplea; y (iv) trabajo futuro, incluyendo transfer learning desde redes preentrenadas, segmentación previa de la región de interés, ampliación del dataset y validación con datos clínicos externos.]