

Clasificación de Tumores Cerebrales en MRI mediante Redes Neuronales Convolucionales propias sobre el Dataset *Brain Tumor Classification MRI*

Abel Albuez Sánchez, Daniel Rios, Juan Torres y Javier Esquivel
Maestría en Analítica para Inteligencia de Negocios (MAIN)
Pontificia Universidad Javeriana, Bogotá D.C., Colombia
Profesor: Julio Omar Palacio Niño, M.Sc. Aprendizaje Profundo 2026

Resumen—La clasificación automática de tumores cerebrales en imágenes de resonancia magnética (MRI) constituye una tarea relevante para el apoyo al diagnóstico radiológico. Este trabajo aborda la clasificación de cuatro categorías —*glioma*, *meningioma*, *pituitary* y *no tumor*— sobre el dataset público *Brain Tumor Classification MRI* de Kaggle (3 264 imágenes), mediante tres arquitecturas propias de redes neuronales convolucionales (CNN) entrenadas desde cero, sin emplear *transfer learning*. Se reporta un análisis exploratorio detallado del dataset —incluyendo distribución por clases, dimensionalidad y estadísticos de intensidad—, un pipeline de preprocesamiento con normalización tipo ImageNet y *data augmentation*, y un protocolo de evaluación basado en *F1-Score* macro, adecuado para escenarios con desbalance de clases.

Index Terms—clasificación de tumores cerebrales, redes neuronales convolucionales, resonancia magnética, aprendizaje profundo, PyTorch, *F1-Score* macro

I. OBJETIVO DEL PROYECTO

I-A. Contexto Clínico

El diagnóstico temprano y preciso de tumores cerebrales constituye uno de los retos más relevantes de la neuro-oncología contemporánea. La resonancia magnética (MRI, *Magnetic Resonance Imaging*) es la modalidad de imagen de referencia para la detección y caracterización de estas lesiones; sin embargo, su interpretación depende fuertemente de la experiencia del radiólogo y está sujeta a variabilidad inter-observador. En este contexto, los sistemas de apoyo al diagnóstico basados en aprendizaje profundo han mostrado resultados prometedores como herramientas de cribado y segunda opinión, capaces de procesar grandes volúmenes de estudios de manera consistente.

I-B. Objetivo Técnico

El presente proyecto tiene como objetivo diseñar, entrenar y evaluar tres arquitecturas propias de redes neuronales convolucionales (CNN) para la clasificación automática de imágenes MRI cerebrales en cuatro categorías: *glioma_tumor*, *meningioma_tumor*, *no_tumor* y *pituitary_tumor*. Se utiliza el dataset público *Brain Tumor Classification MRI* disponible en Kaggle. De manera explícita, este trabajo **no** emplea técnicas de *transfer learning* ni pesos preentrenados sobre ImageNet u otros corpus; el énfasis pedagógico está en la construcción de arquitecturas convolucionales desde cero y en la comprensión del impacto de sus hiperparámetros y bloques constitutivos.

I-C. Criterios de Evaluación

La evaluación de los modelos se realizará mediante un conjunto de métricas clásicas de clasificación multiclase: *Accuracy*, *Precision*, *Recall* y *F1-Score* en su variante *macro-averaged*, complementadas con la matriz de confusión por modelo. Dado el desbalance entre clases observado durante el análisis exploratorio (Sección II), el *F1-macro* se adopta como métrica principal de comparación, por su robustez frente a clases minoritarias.

II. ANÁLISIS DEL DATASET Y DIMENSIONALIDAD

II-A. Descripción del Dataset

El conjunto de datos *Brain Tumor Classification MRI* contiene **3 264 imágenes** MRI cerebrales distribuidas en cuatro clases, particionadas en conjuntos de entrenamiento y prueba por los autores originales. La Tabla I resume su distribución.

Cuadro I: Distribución de imágenes por clase y partición.

Clase	Train	Test	Total
glioma_tumor	826	100	926
meningioma_tumor	822	115	937
no_tumor	395	105	500
pituitary_tumor	827	74	901
Total	2 870	394	3 264

El conjunto de entrenamiento concentra el **87,9 %** de las imágenes (2 870), mientras que el conjunto de prueba representa el **12,1 %** restante (394 imágenes). Esta partición oficial se respeta como *holdout* independiente para la evaluación final, y el conjunto de entrenamiento se sub-divide internamente para validación (Sección IV-B).

II-B. Balance de Clases

El análisis de balance evidencia que la clase *no_tumor* es la minoritaria, con aproximadamente **395** imágenes en entrenamiento, frente a **~825** para cada una de las clases tumorales. Esta proporción asimétrica ($\sim 1:2$) puede inducir sesgos durante el aprendizaje, llevando al modelo a sub-representar la clase minoritaria.

Como estrategia de compensación se adopta el uso de pesos por clase (*class_weight*) en la función de pérdida *Cross-Entropy*, con ponderaciones inversamente proporcionales a la

frecuencia relativa de cada clase en el conjunto de entrenamiento. Esto incrementa la magnitud del gradiente para errores cometidos sobre la clase minoritaria sin alterar la distribución de muestras observadas. Las Figuras 1 y 2 ilustran gráficamente esta distribución.




Figura 1: Distribución absoluta de imágenes por clase y partición.




Figura 2: Proporción relativa de las clases en el conjunto de entrenamiento.

II-C. Análisis de Dimensionalidad

Se inspeccionó una muestra de 80 imágenes por clase para caracterizar la variabilidad en resolución espacial. El dataset presenta resoluciones altamente heterogéneas: las dimensiones máximas observadas alcanzan **1024×768 px** y las mínimas **59×80 px**. Además, la relación de aspecto varía considerablemente entre estudios, debido a las diferencias entre equipos de adquisición y protocolos clínicos.

Dada esta heterogeneidad, se establece el redimensionamiento uniforme a **224×224 px** como paso obligatorio del pipeline. Este tamaño constituye un compromiso entre detalle anatómico preservado y costo computacional, y es además el formato canónico de las arquitecturas CNN modernas, lo que facilita comparaciones posteriores. Las Figuras 3 y 4 muestran respectivamente el histograma de resoluciones y la distribución de relaciones de aspecto.




Figura 3: Histograma de resoluciones (ancho × alto) en el dataset.




Figura 4: Distribución de relaciones de aspecto observadas por clase.

II-D. Análisis Estadístico de Intensidades

Se analizaron las distribuciones de intensidad de píxeles (escala de grises) y canales RGB por clase, con el fin de identificar diferencias fotométricas discriminativas. La Tabla II resume los estadísticos descriptivos por clase.

Cuadro II: Estadísticas de intensidad (escala 0–255) por clase.

Clase	Media	Std	Min	Max	Mediana
glioma_tumor	36,23	41,43	0	255	14
meningioma_tumor	44,56	47,77	0	255	28
no_tumor	52,21	59,63	0	255	22
pituitary_tumor	49,50	42,94	0	255	50

Se observa que los *gliomas* presentan los valores más bajos de media e intensidad mediana, lo que los caracteriza como tejidos relativamente **hipointensos** en la modalidad analizada. Los tumores *pituitarios*, en contraste, presentan la mediana más alta (50) y la menor dispersión relativa, indicando intensidades más concentradas y homogéneas. La clase *no_tumor*

muestra la mayor desviación estándar (59,63), consistente con la variedad anatómica del cerebro sano sin focalización lesional. Estas diferencias fotométricas constituyen señales útiles que una CNN puede explotar a nivel de filtros convolucionales de bajo nivel.

Para estabilizar el entrenamiento se aplicará normalización *Z-score* sobre los tres canales utilizando los estadísticos canónicos de ImageNet ($\mu = [0,485, 0,456, 0,406]$, $\sigma = [0,229, 0,224, 0,225]$). Las Figuras 5 y 6 complementan visualmente este análisis.




Figura 5: Diagramas de caja de intensidades de píxel por clase.




Figura 6: Distribución de intensidades por canal RGB y por clase.

II-E. Imagen Promedio y Muestras por Clase

La Figura 7 presenta la imagen promedio por clase, calculada como la media píxel a píxel de 100 imágenes redimensionadas a 224×224 px. Los gliomas exhiben regiones **hipointensas difusas**, de bordes poco definidos, consistente con su naturaleza infiltrativa. Los tumores *pituitarios* tienden a concentrarse en la zona central de la imagen, reflejando la ubicación anatómica de la glándula hipófisis. Los meningiomas muestran patrones intermedios con tendencia a localizarse en

la periferia. La clase *no_tumor*, al promediar tejidos cerebrales sanos con distintas orientaciones, produce una imagen más difusa y centralmente simétrica.



Figura 7: Imagen promedio por clase (100 imágenes, 224×224 px).

La Figura 8 ilustra cinco ejemplos representativos por clase. Se evidencia alta variabilidad intra-clase en orientación, escala y contraste, lo que justifica el uso de *data augmentation* durante el entrenamiento para mejorar la capacidad de generalización del modelo.




Figura 8: Muestras representativas (5 por clase) del conjunto de entrenamiento.

II-F. Plan de Preprocesamiento

A partir de los hallazgos anteriores, se define el pipeline de preprocesamiento resumido en la Tabla III.

Cuadro III: Pipeline de preprocesamiento propuesto.

#	Paso	Justificación
1	Resize 224×224 px	Resoluciones heterogéneas requieren entrada uniforme.
2	Conversión a RGB	Algunas imágenes están en escala de grises; se unifica el formato.
3	Z-score (μ ImageNet)	Estabiliza el gradiente y mejora la convergencia.
4	<i>Data augmentation</i>	Rotación $\pm 15^\circ$, flip horizontal y variación de brillo: compensa la variabilidad intra-clase.
5	<i>class_weight</i>	Compensa el desbalance de la clase <i>no_tumor</i> .
6	Split 80/20 <i>Training</i>	Separa validación interna sin contaminar el <i>holdout</i> oficial.

III. METODOLOGÍA

III-A. Métricas de Evaluación

Para evaluar las arquitecturas propuestas se emplea un conjunto de métricas estándar de clasificación multiclase:

- **Accuracy:** proporción global de aciertos, $\text{Acc} = (TP + TN) / (TP + TN + FP + FN)$.
- **Precision (macro):** promedio no ponderado de la precisión por clase, $\frac{1}{C} \sum_c TP_c / (TP_c + FP_c)$.
- **Recall (macro):** promedio no ponderado de la sensibilidad por clase, $\frac{1}{C} \sum_c TP_c / (TP_c + FN_c)$.
- **F1-Score (macro):** media armónica de Precision y Recall, $F1 = 2 \cdot P \cdot R / (P + R)$, calculada por clase y promediada de forma no ponderada.
- **Matriz de confusión:** análisis cualitativo de los errores entre pares de clases.

Dado el desbalance descrito en la Sección II, la *Accuracy* puede ser engañosa, pues un modelo que ignore por completo la clase *no_tumor* aún alcanzaría valores razonables. El **F1-Score macro** otorga el mismo peso a todas las clases sin considerar su frecuencia, por lo que penaliza explícitamente los modelos que descuidan las clases minoritarias. Por esta razón se adopta como métrica principal de comparación entre los tres modelos.

III-B. Arquitectura Modelo 1 — CNN Baseline

[PENDIENTE: incluir tabla con la especificación capa por capa del modelo *model 1* (bloques *Conv2d* $\rightarrow$ *ReLU* $\rightarrow$ *MaxPool*, número de filtros, tamaño de kernel, capas *fully-connected* finales y número total de parámetros entrenables).]

III-C. Arquitectura Modelo 2 — CNN Profunda

[PENDIENTE: descripción detallada del *model 2*, incluyendo el uso de *Batch Normalization* entre las capas convolucionales, *Dropout* en las capas densas, mayor profundidad (bloques convolucionales adicionales) y justificación de cada elemento frente al *baseline*.]

III-D. Arquitectura Modelo 3 — CNN con Técnica Avanzada

[PENDIENTE: descripción del *model 3*, integrando una técnica avanzada construida desde cero (por ejemplo, bloques residuales tipo *ResNet*, *Global Average Pooling*, módulos de atención o conexiones densas), manteniendo la restricción de no usar pesos preentrenados.].

IV. ENTRENAMIENTO E IMPLEMENTACIÓN

IV-A. Hiperparámetros

[PENDIENTE: incluir tabla comparativa de hiperparámetros por modelo (tasa de aprendizaje, batch size, número de épocas, optimizador — p. ej. *Adam/SGD con momentum* —, *learning rate scheduler*, *weight decay* y función de pérdida *CrossEntropyLoss con class_weight*).]

IV-B. Protocolo de Entrenamiento

La implementación se realiza íntegramente en **Python** con **PyTorch**, mediante *scripts* locales organizados en el directorio *src/*. El flujo de trabajo reproducible es el siguiente:

1. Crear un entorno virtual aislado: `python -m venv .venv` y activarlo.
2. Instalar dependencias: `pip install -r requirements.txt`.
3. Lanzar el entrenamiento de un modelo específico: `python src/models/train.py --model N --data_dir datasets/Training`, con $N \in \{1, 2, 3\}$.
4. Los *checkpoints* de pesos se almacenan en `outputs/results/` y las métricas por época se registran incrementalmente en `outputs/results/metrics.csv`.
5. La evaluación final sobre el conjunto de prueba se ejecuta con:
`python src/models/evaluate.py --model N --data_dir datasets/Testing`.

Se aplica una división interna **80/20** sobre el conjunto *Training* para obtener un *validation set* usado en la monitorización de pérdida y métricas durante el entrenamiento y en la selección del mejor *checkpoint*. El conjunto *Testing* original se reserva como *holdout* independiente y solo se emplea en la evaluación final reportada en la sección de resultados.

V. RESULTADOS

V-A. Métricas por Modelo

[PENDIENTE: incluir tabla comparativa con *Accuracy*, *Precision (macro)*, *Recall (macro)* y *F1-Score (macro)* obtenidos sobre el conjunto de prueba para *model 1*, *model 2* y *model 3*.]

V-B. Análisis por Clase

[PENDIENTE: tabla con *F1-Score* por clase para cada modelo, destacando las clases con menor desempeño. Se anticipa que *meningioma_tumor* podría ser la clase más difícil debido a la similitud visual de sus patrones con otras lesiones intracraneales.].

V-C. Matrices de Confusión

[PENDIENTE: inserción de `\includegraphics` con las matrices de confusión generadas en `confusion_modelN.png` para los tres modelos, con análisis cualitativo de los principales patrones de error.].

V-D. Curvas de Entrenamiento

[PENDIENTE: curvas de loss y accuracy (train vs. val) por época para cada modelo, generadas desde outputs/results/metrics.csv, con análisis de convergencia, presencia de overfitting y efectividad del scheduler.]

VI. CONCLUSIONES

[PENDIENTE: discusión final estructurada en cuatro ejes: (i) si los resultados obtenidos por las CNN propias permiten considerar el sistema como una herramienta de apoyo diagnóstico clínicamente confiable; (ii) análisis de las clases problemáticas y sus posibles causas (similitud fotométrica, desbalance, variabilidad intra-clase); (iii) limitaciones del enfoque sin transfer learning y comparación cualitativa con literatura que sí lo emplea; y (iv) trabajo futuro, incluyendo transfer learning desde redes preentrenadas, segmentación previa de la región de interés, ampliación del dataset y validación con datos clínicos externos.]