

TAREA DE INVESTIGACIÓN FINE TUNING MRI

Este trabajo fue desarrollado por:

Javier Alejandro Esquivel, Abel Albuez Sánchez, Daniel Rios y Juan Torres

1. Introducción

El análisis de imágenes médicas mediante técnicas de resonancia magnética (MRI) constituye una de las herramientas diagnósticas más críticas en la neurología contemporánea. Una detección temprana altera drásticamente el pronóstico y el esquema terapéutico de los pacientes. No obstante, la interpretación manual de estas imágenes representa una tarea de alta complejidad que exige una inversión significativa de tiempo por parte de especialistas y está sujeta al criterio de cada evaluador

2. Metodología

Para el desarrollo del sistema de clasificación, se implementó un flujo de trabajo basado en el Aprendizaje por Transferencia (Transfer Learning) y Ajuste Fino (Fine-Tuning). Esta sección describe la arquitectura del modelo avanzado, la estrategia de selección de capas para el re-entrenamiento y la configuración de los hiperparámetros que gobernaron el proceso de optimización.

2.1. Descripción de la arquitectura implementada

Como núcleo del sistema de extracción de características visuales se seleccionó la arquitectura VGG16, una red neuronal convolucional profunda pre-entrenada con el conjunto de datos a gran escala ImageNet. La elección de VGG16 se fundamenta en su arquitectura homogénea y probada eficacia en la identificación de patrones de textura complejos, propiedades críticas al trabajar con imágenes de resonancia magnética.

A la arquitectura base se le removió la cabeza de clasificación original (`include_top=False`) correspondiente a las 1,000 clases generalistas. En su lugar, se acopló un bloque clasificador personalizado diseñado a medida para las necesidades diagnósticas del dataset. La arquitectura avanzada final quedó constituida por la siguiente secuencia de bloques funcionales:

- **Extractor de Características Base (VGG16):** Compuesto por 13 capas convolucionales organizadas en 5 bloques jerárquicos intercalados con capas de max-pooling. Recibe como entrada tensores con dimensiones de $224 \times 224 \times 3$ procesados mediante la función de normalización nativa de la red.
- **Capa de Aplanado (Flatten):** Transforma los mapas de características tridimensionales de la última capa convolucional en un vector unidimensional de características de alta abstracción.

- Capa Densa Intermedia (Capa densa): Una capa totalmente conectada con 256 neuronas y función de activación ReLU para introducir no-linealidad y aprender combinaciones complejas de las características médicas extraídas.
- Capa de Regularización (Dropout): Configurada con una tasa de 0.4 (40% de desactivación de neuronas por ciclo de entrenamiento). Esta desconexión aleatoria actúa como un mecanismo de control de sobreajuste (overfitting), forzando a la red a aprender representaciones redundantes y robustas, mitigando la naturaleza limitada del dataset clínico.
- Capa de Salida (Output Layer): Una capa densa final con 4 neuronas — correspondientes a las categorías glioma_tumor, meningioma_tumor, no_tumor y pituitary_tumor— gobernada por la función de activación Softmax para mapear las salidas en una distribución de probabilidad multiclase.

2.2. Estrategia de descongelamiento de capas

El entrenamiento se estructuró de manera estricta en una estrategia de Fine-Tuning Bifásico para garantizar la estabilidad de los pesos pre-entrenados:

- Fase 1: Calentamiento del Clasificador (Congelamiento Total): Durante las primeras 5 épocas, el modelo base VGG16 se configuró como no-entrenable. Esto permitió que los pesos de las capas convolucionales permanecieran estáticos, aislando el gradiente para que únicamente el nuevo clasificador denso se adaptara a la distribución de los datos médicos sin corromper el conocimiento previo de la red.
- Fase 2: Ajuste Fino: Una vez estabilizado el clasificador, se procedió a la apertura selectiva de la red. Se liberó exclusivamente el último bloque convolucional (Bloque 5), el cual comprende las capas block5_conv1, block5_conv2 y block5_conv3. El resto de la red (Bloques 1 al 4) se mantuvo congelado de manera permanente. La lógica técnica detrás de esta selección radica en que las primeras capas de una CNN capturan características primitivas generales como lo pueden ser bordes y esquinas, mientras que las capas del bloque final procesan morfologías complejas y de alta jerarquía, siendo estas últimas las que requerían mayor atención.

2.3. Hiperparámetros

A continuación, se describen los hiperparámetros usados. Como punto clave se puede observar que en la Fase 2 se reduce drásticamente la tasa de aprendizaje para evitar el olvido, permitiendo ajustes infinitesimales en el Bloque 5. Respecto a las épocas se hizo un reparto temporal para asegurar primero el acople del clasificador y posteriormente dar margen a la convergencia del Fine-Tuning. Por último, la dimensión de entrada se establece una resolución estándar requerida por el grafo computacional nativo de VGG16.

Hiperparámetro	Valor en la fase 1	Valor en la fase 2
Optimizador	Adam	Adam
Tasa de aprendizaje	0.001	0.00001
Función de pérdida	Crossentropy	Crossentropy
Tamaño del batch	32	32
Epocas	5	12
Dimensión de entrada	224 X 224 X 3	224 X 224 X 3


3. Resultados

El entrenamiento tomó aproximadamente una hora en completarse generando los siguientes resultados.


3.1. Métricas

=====				
REPORT DE CLASIFICACIÓN (VGG16)				
=====				
	precision	recall	f1-score	support
glioma_tumor	0.92	0.22	0.35	100
meningioma_tumor	0.64	0.96	0.77	115
no_tumor	0.72	0.96	0.82	105
pituitary_tumor	0.93	0.72	0.81	74
accuracy			0.73	394
macro avg	0.80	0.71	0.69	394
weighted avg	0.78	0.73	0.68	394
=====				

3.2. Matriz de confusión:



3.3. Gráficos de curvas de pérdida y precisión



3.3. Comparativa de métricas con resultado del proyecto final

Clase / Métrica	Precisión (Precision)	Sensibilidad (Recall)	F1-Score	Soporte (Support)
-----------------	-----------------------	-----------------------	----------	-------------------

Glioma				
* Modelo Propio	1.0000	0.1700	0.2906	100
* VGG16 (Fine-Tuning)	0.9200	0.2200	0.3500	100
Meningioma				
* Modelo Propio	0.6835	0.9391	0.7912	115
* VGG16 (Fine-Tuning)	0.6400	0.9600	0.7700	115
Sin Tumor (Sano)				
* Modelo Propio	0.6538	0.9714	0.7816	105
* VGG16 (Fine-Tuning)	0.7200	0.9600	0.8200	105
Pituitary				
* Modelo Propio	0.8413	0.7162	0.7737	74
* VGG16 (Fine-Tuning)	0.9300	0.7200	0.8100	74
MÉTRICAS GLOBALES				
Exactitud (Accuracy)	—	—	0.7107 (Propio) / 0.7300 (VGG16)	394
Promedio Macro (Macro Avg)	0.7947 / 0.8000	0.6992 / 0.7100	0.6593 / 0.6900	394
Promedio Ponderado (Weighted Avg)	0.7856 / 0.7800	0.7107 / 0.7300	0.6583 / 0.6800	394

4. Análisis y conclusiones

Se puede evidenciar que la arquitectura propuesta del *fine tuning* de VGG16 exhibe una solidez superior en las tres métricas globales centrales. Consigue elevar el Accuracy al 73% (frente al 71.07% del modelo propio) y, de manera más significativa, incrementa el F1-Score Macro a 0.69 (frente a 0.6593). Este comportamiento valida estadísticamente que los mapas de características pre-entrenados en capas inferiores, combinados con la sintonización del Bloque 5, proveen un mejor balance adaptativo para resolver tareas multiclase. No obstante, El comportamiento ante los gliomas revela cómo cada topología ha configurado sus fronteras de decisión de forma distinta. Por un lado, el modelo Propio alcanza una precisión perfecta del 100% lo que significa que el hiperplano de clasificación se contrajo al punto de solo etiquetar como glioma aquellos casos con una certeza absoluta. El costo de esta rigidez es un Recall crítico de apenas el 17%. Por otro lado, el modelo VGG16 flexibiliza ligeramente la frontera rebajando la precisión al 92%, pero a cambio rescata un mayor volumen de muestras patológicas reales, elevando el Recall al 22%.

Aunque ambos puntajes de sensibilidad siguen siendo deficientes para un despliegue clínico real, VGG16 demuestra una mayor capacidad de discriminación en entornos con alta incertidumbre textural, consolidando un F1-score superior (0.35 vs. 0.29). Uno de los mayores logros del Fine-Tuning con VGG16 se observa en las clases `no_tumor` (pacientes sanos) y `pituitary_tumor`. En los tumores pituitarios, VGG16 incrementa drásticamente la precisión del 84.13% al 93% manteniendo un *Recall* equivalente. De igual forma, en la clase de cerebros sanos, eleva la precisión del 65.38% al 72%.

Esto evidencia que el modelo avanzado es más eficiente reduciendo los falsos positivos.

4.1 Desafío en la implementación

Respecto al nivel de desafío en la implementación podría decirse que fue de nivel intermedio. A pesar de que en internet se pueden encontrar tutoriales para resolver específicamente este tipo de problemas los resultados varían al momento de su implementación y existen errores que requieren de consulta para determinar que hacen ciertas líneas de códigos no explicadas en el tutorial y que otro enfoque se puede tomar para resolver el problema y continuar. El siguiente tutorial fue de bastante ayuda para implementar la solución al problema:

<https://medium.com/@goktani/brain-tumor-detection-with-vgg16-a-complete-guide-to-transfer-learning-and-fine-tuning-on-mri-2f49775cf30a>

Respecto al costo computacional es bastante alto logrando ocupar los 16 núcleos del computador durante aproximadamente hora y media para realizar el entrenamiento. Misma razón por la que se optó por tener un número bajo de épocas para poder avanzar.